

符號說明

其他文件裡用到的所有符號都在這裡。**建議先看這份**，尤其是 $\odot$ 和 $@$ 那一節——這兩個都叫「乘」，但完全是兩回事，混淆的話後面每條公式都會讀錯。

可執行的對照示範：

```
python tools/demo_operators.py
```

最容易混淆的兩個： $\odot$ 與 $@$

$\odot$ 逐元素相乘 (Hadamard product)

$$(A \odot B)_{ij} = A_{ij} \times B_{ij}$$

位置對位置相乘，形狀不變。

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$$
$$A \odot B = \begin{bmatrix} 1 \times 5 & 2 \times 6 \\ 3 \times 7 & 4 \times 8 \end{bmatrix} = \begin{bmatrix} 5 & 12 \\ 21 & 32 \end{bmatrix}$$

左上角那格 $= 1 \times 5 = 5$ 。每一格只跟「同一格」的對手相乘，跟其他格完全無關。

$@$ 矩陣乘法 (matrix multiplication)

$$(A @ B)_{ij} = \sum_k A_{ik} \times B_{kj}$$

左邊的「列」跟右邊的「行」做點積。



$$A @ B = \begin{bmatrix} 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 \\ 3 \times 5 + 4 \times 7 & 3 \times 6 + 4 \times 8 \end{bmatrix} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$$

左上角那格 $= 1 \times 5 + 2 \times 7 = 19$ 。用到了一整列和一整行，也就是所有維度。

同樣的輸入，結果完全不同

	$A \odot B$	$A @ B$
左上角	5	19
算法	一對一相乘	一整列 · 一整行
形狀	必須相同，輸出也相同	$(m, k) @ (k, n) \rightarrow (m, n)$
會不會混合維度	不會	會

為什麼「會不會混合維度」是關鍵



⊙ 的每一條線都是平行的，資訊不會橫向流動。@ 的每個輸出都吃進了所有輸入。

這決定了它們在模型裡的角色：

符號	出現在哪	做什麼
@	Linear : $y = x @ W^T$	把 d 維換成另外 d_{out} 維
@	Attention : QK^T	每個位置跟每個位置做點積
@	輸出層 : hE^T	隱藏狀態跟每個詞向量做點積
⊙	RMSNorm : $y = g \odot \hat{x}$	每個維度乘上自己的縮放係數
⊙	SwiGLU : $m = s \odot u$	閘門：每個維度各自決定放行多少
⊙	RoPE : $x \odot \cos$	每個維度乘上自己的旋轉係數

⊙ 永遠不會把不同維度的資訊混在一起。所以模型的「學習能力」幾乎全部來自 @，⊙ 只負責調整強度。

這也解釋了為什麼「疊很多個 ⊙」沒有用——不管乘幾次，維度 1 永遠只影響維度 1。

形狀規則

x shape (4, 8)

$x @ W.T \rightarrow (4, 3)$ $(4, 8) @ (8, 3)$ 最後一維被換掉了

$x \odot g \rightarrow (4, 8)$ $(4, 8) \odot (8,)$ 形狀完全不變

$x \odot g$ 用到了廣播 (broadcasting)： g 只有 8 個數字，會自動複製 4 份，對 x 的每一列各做一次逐元素相乘。

反向傳播的規則也不一樣

$$y = a \odot b \implies \frac{\partial L}{\partial a} = \frac{\partial L}{\partial y} \odot b, \quad \frac{\partial L}{\partial b} = \frac{\partial L}{\partial y} \odot a$$

$$y = x @ W^T \implies \frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} @ W, \quad \frac{\partial L}{\partial W} = \left(\frac{\partial L}{\partial y} \right)^T @ x$$

兩個都符合同一句話：對其中一邊微分，得到的就是另一邊。

`tools/demo_operators.py` 用有限差分驗證了這兩條，誤差 10^{-10} 等級。

其他符號

運算

符號	名稱	意思
$\cdot$	點積	兩個向量對應相乘後加總，得到一個 純量 ： $a \cdot b = \sum_k a_k b_k$
$\otimes$	外積	兩個向量產生一個 矩陣 ： $(a \otimes b)_{ij} = a_i b_j$
$A^\top$	轉置	列與行互換： $(A^\top)_{ij} = A_{ji}$
$\sum_k$	求和	對指標 k 把所有項加起來
$\ x\ $	範數	向量長度： $\sqrt{\sum_k x_k^2}$
$\leftarrow$	賦值	「用右邊的值取代左邊」，不是等式

$\cdot$ 和 $@$ 的關係： $@$ 就是把 $\cdot$ 做很多次。 $(A @ B)_{ij}$ 就是「 A 的第 i 列」 $\cdot$ 「 B 的第 j 行」。

微分

符號	意思
$\frac{\partial L}{\partial x}$	L 對 x 的偏導數。白話：「把 x 動一丁點， L 會變多少」
$\frac{\partial L}{\partial \mathbf{x}}$	對整個向量微分，結果跟 $\mathbf{x}$ 同形狀
$f'(z)$	單變數函數的導數
δ_{ij}	Kronecker delta： $i = j$ 時為 1，否則為 0

程式碼裡為了簡潔， $\frac{\partial L}{\partial x}$ 一律寫成 `dx`。

函數

符號	定義
$\sigma(z)$	sigmoid： $\frac{1}{1 + e^{-z}}$ ，把任意實數壓到 (0, 1)
$\text{SiLU}(z)$	$z \sigma(z)$ ，也叫 Swish
$\text{softmax}(\mathbf{z})_i$	$\frac{e^{z_i}}{\sum_k e^{z_k}}$ ，把一排分數變成機率（和為 1）
$\text{mean}(x)$	平均值

形狀與維度

符號	意思	本專案的典型值
B	batch size，一次處理幾段文字	64
T	序列長度，一段文字幾個 token	128
d	模型維度 (hidden size)	256
h	attention head 數	4
d_{head}	每個 head 的維度， $= d/h$	64
d_{ff}	FFN 的中間維度	672
$ \mathcal{V} $	詞表大小	6400
N	一個 batch 裡有效的預測位置數	$B \times T$

張量形狀寫成 (B, T, d) ，最後一維永遠是「特徵維度」。

常見的讀法陷阱

① $W^{\top}$ 出現在哪一邊

程式碼寫 `x @ W.T`，因為 PyTorch 的慣例是 W 的形狀為 $(d_{\text{out}}, d_{\text{in}})$ 。所以要先轉置才對得上。數學文獻常寫成 Wx (W 在左)，兩者是同一件事，只是排列不同。

② $\frac{\partial L}{\partial W}$ 的形狀

永遠跟 W 一樣。梯度是「每個參數各自的斜率」，所以有幾個參數就有幾個梯度。

③ $\leftarrow$ 不是 $=$

$$\theta \leftarrow \theta - \eta g$$

這是「更新」：用右邊算出來的值取代左邊。寫成 $\theta = \theta - \eta g$ 在數學上是個無解的方程式。