

詞表大小是怎麼決定的

「minimind 的詞表 6400 個 token，這個數字是哪來的？」

不是算出來的，是你自己挑的停止條件。

$$|\mathcal{V}| = \underbrace{|\mathcal{V}_0|}_{\text{起始符號數}} + \underbrace{M}_{\text{合併次數}}$$

BPE 每合併一次，詞表就多一個。想要 $|\mathcal{V}| = 6400$ ，就合併到總數變成 6400 為止。

實際跑一次的數字

```
python tests/test_bpe.py
```

詞塊 183,640 個（相異 74,440 個），字元 546,000 個


起始詞表 3,653（4 特殊 + 3,649 字元）

目標 6,400 → 需要合併 2,747 次

$$3,653 + 2,747 = 6,400$$

看最後一行。就這麼直接。

BPE 在做什麼



沒有任何學習、沒有梯度、沒有神經網路。純粹是貪婪的頻率統計。

合併過程長什麼樣

`traces/bpe_training.txt` 會記下每一次合併：

```
合併 #1      ('可', '以') 出現 2,362 次 -> 新 token '可以'    詞表 3,654
合併 #2      ('我', '們') 出現 1,988 次 -> 新 token '我們'    詞表 3,655
...
合併 #1000   ('歌', '詞') 出現   40 次 -> 新 token '歌詞'    詞表 4,653
合併 #2000   ('排', '放') 出現   21 次 -> 新 token '排放'    詞表 5,653
```

注意**出現次數一路遞減**：2362 → 1988 → ... → 40 → 21。

這給了一個很實用的判斷：**如果最後幾次合併的次數已經降到個位數，代表詞表開太大了**，那些 token 學不到什麼東西。反過來，如果停下來的時候 次數還有好幾百，代表還可以再擴。

效果

500 段，共 140,502 字元

字元級 140,502 tokens 1.000 token/字

BPE 99,202 tokens 0.706 token/字

BPE 讓序列短了 29.4%

切分對照：

原文 機器學習是人工智慧的一個分支

字元級 ['機','器','學','習','是','人','工','智','慧','的','一','個','分','支']

BPE ['機器學習','是','人','工智慧','的一個','分','支']

機器學習 變成一個 token 了。序列變短的直接好處：

- 同樣的 context window 能裝更多內容
- Attention 是 $O(n^2)$ ，序列短一半，注意力的計算量剩四分之一

為什麼順序不能亂

編碼的時候要**照訓練時學到的順序**套用合併：

'機器學習' 這個 token 存在的前提，是 '機器' 和 '學習' 已經先被合併出來了。

所以 `bpe.py` 裡每個合併都記了 `rank`（第幾次學到的），編碼時永遠先套 `rank` 最小的。

這份實作與生產級的差別

	這裡	GPT-2 / Qwen / minimind
起始符號	語料裡的 字元	256 個 byte
OOV	用 <code><unk></code>	不可能有（任何字都能拆成 byte）
追蹤檔可讀性	每個符號都是你認得的字	生僻字會變成看不懂的 byte 碎片

byte-level 的代價，在前面的實驗裡量過：用簡體訓的 tokenizer 去吃繁體語料時，「這」會被拆成兩個 byte 碎片，序列長度膨脹 1.67 倍。因為那些繁體字**根本不在詞表裡**。

這也是為什麼換語言、換領域時，tokenizer 常常得重訓。

一個容易忽略的連結

詞表大小直接決定了 embedding 的參數量：

$$|\theta_{\text{embed}}| = |\mathcal{V}| \times d$$

$6400 \times 768 = 4,915,200$ 。詞表開兩倍，embedding 就大兩倍。

而且因為 weight tying，同一個矩陣還兼任輸出層——所以詞表大小也直接決定了最後那個 logits 張量有多大：

$$\text{logits} \in \mathbb{R}^{B \times T \times |\mathcal{V}|}$$

那通常是訓練時**最大的中間張量**。以 $B=64$ 、 $T=128$ 、 $|\mathcal{V}|=6400$ 為例，光這一個張量就有 5.24×10^7 個數字。

詞表大小不只是 tokenizer 的參數，它同時是模型的架構參數。