

完整執行紀錄

從乾淨狀態跑完整條流程，每個階段都是「指令 → 程式碼在做什麼 → 實際輸出」三段式。

這份文件怎麼讀

追蹤檔的資料量很大——單一個 `train_step_0001.txt` 就有 **926 行 / 59 KB**。全部貼出來沒有意義，所以這裡採三層呈現：

層	做什麼	在哪
摘要	一張表說明產出了什麼檔案、多大、要看什麼	產出的檔案
骨架	長檔案的章節目錄與行號，知道去哪裡找	怎麼讀 926 行的追蹤檔
精選	5 個關鍵片段，配上對應的程式碼	下面每個階段

原則：這份文件負責告訴你「該看哪幾行」，不負責取代那些檔案。

環境

GPU	NVIDIA RTX PRO 6000 Blackwell (96 GB)
Python	3.12, torch 2.9.1+cu130
語料	<code>data/corpus_zhtw.jsonl</code> 前 20,000 行
總耗時	梯度驗證 3 秒 + BPE 訓練 12 秒 + 模型訓練 79 秒

```
rm -rf out traces          # 從乾淨狀態開始
```

階段 1：驗證所有手推的公式

```
python tests/test_layers.py
```

程式碼在做什麼

不用 PyTorch 的 autograd 對答案，而是回到梯度的**定義**直接量：

$$\frac{\partial L}{\partial w} \approx \frac{L(w + \varepsilon) - L(w - \varepsilon)}{2\varepsilon}$$

```
# scratch/gradcheck.py (節錄)
y0 = layer.forward(x)
dy = torch.randn(y0.shape)      # 隨機的上游梯度
dx = layer.backward(dy)          # 手推公式算出來的

flat[i] = orig + eps; lp = float((layer.forward(x) * dy).sum())
flat[i] = orig - eps; lm = float((layer.forward(x) * dy).sum())
num = (lp - lm) / (2 * eps)      # 有限差分算出來的
rel = abs(num - float(dx.reshape(-1)[i])) / ...
```

人工造一個純量 $\text{loss } L = \sum(y \odot dy)$ ，這樣 $\partial L / \partial y$ 剛好等於 dy ，就能用任意的 dy 去測 backward 對不對。

用**中央差分**而不是單邊，因為誤差是 $O(\epsilon^2)$ 而不是 $O(\epsilon)$ 。整個檢查跑在 `float64` 上，避免 `float32` 的捨入誤差蓋過訊號。

實際輸出

梯度檢查（有限差分 vs 手推公式）

```
=====
Linear 無bias          最大相對誤差 2.29e-12  PASS
Linear 有bias          最大相對誤差 2.03e-12  PASS
RMSNorm                最大相對誤差 2.13e-07  PASS
Embedding (scatter-add) 最大相對誤差 6.80e-14  PASS
TiedOutputHead         最大相對誤差 5.61e-12  PASS
SwiGLU                 最大相對誤差 1.69e-06  PASS
rope                   最大相對誤差 2.19e-12  PASS
Attention               最大相對誤差 3.32e-07  PASS
Softmax+CrossEntropy   最大相對誤差 7.50e-08  PASS
=====
最差相對誤差 1.69e-06  -> 全部通過
```

誤差大小的差異是有意義的：純矩陣運算的層（Linear、Embedding、RoPE）在 10^{-12} 等級，含開根號、除法、 $\sigma(1 - \sigma)$ 的層（RMSNorm、SwiGLU）在 $10^{-6} \sim 10^{-7}$ ，因為浮點誤差會累積。

階段 2：訓練 BPE tokenizer

```
python train.py --tokenizer bpe --vocab 6400 ...
```

程式碼在做什麼

$$|\mathcal{V}| = |\mathcal{V}_0| + M$$

反覆合併最高頻的相鄰配對，每合併一次詞表 +1，到目標大小就停。

```
# tokenizer/bpe.py (節錄)
for step in range(n_merges):
    pair, cnt = max(pair_cnt.items(), key=lambda kv: kv[1]) # 最高頻的配對
    new_sym = pair[0] + pair[1]
    for i in pair_where[pair]: # 只更新受影響的詞塊
        deindex_word(i)
        ...把 pair 換成 new_sym...
        index_word(i)
    tk.merges.append(pair)
    tk.itos.append(new_sym) # 詞表 +1
```

`pair_where` 記錄「哪些詞塊含有這個配對」，合併時只更新受影響的那些，不用每輪重掃整份語料——否則 1,173 次合併會跑很久。

實際輸出

```
詞塊 1,826,987 個（相異 599,629 個），字元 5,415,807 個
起始詞表 5,227（4 特殊 + 5,223 字元）
目標 6,400 → 需要合併 1,173 次

合併 #1      '可' + '以' -> '可以'（23,763 次）  詞表 5,228
合併 #1000   '生' + '產' -> '生產'（393 次）   詞表 6,227

完成，最終詞表 6,400
```

$5,227 + 1,173 = 6,400$ 。這就是「詞表 6400 哪來的」的答案。

注意合併次數一路遞減：23,763 → 393。這給了一個實用判斷——如果最後幾次合併降到個位數，代表詞表開太大了。

完整的合併紀錄：`traces/bpe_training.txt`（54 行）

階段 3：訓練模型

模型規格

模型結構

=====	
embedding	1,638,400
block0	778,752
block1	778,752
block2	778,752
block3	778,752
final_norm	256
lm_head (與 embedding 共用)	0

總計	4,753,664
embedding 佔比	34.5%

optimizer 拿到 38 個參數張量

`lm_head` 是 0，因為它跟 embedding 共用同一個張量（weight tying）。`optimizer` 拿到 38 個張量——**embedding 就在這 38 個裡面**，跟 `q_proj` 平起平坐。

訓練迴圈

```
# train.py (節錄)
model.zero_grad()
logits = model.forward(x, tr)      # 前向
loss   = ce.forward(logits, y, tr) # 算 loss
dlogits = ce.backward(tr)          # dz = (p - y) / N
model.backward(dlogits, tr)         # 反向，逐層往下

gnorm = opt.clip_grad_norm(args.clip) # 全域梯度裁剪
opt.step(tr, watch='embed.E')         # 這一行才真的改動權重
```

注意 `model.backward()` 和 `opt.step()` 是兩件事。前者只算出「該往哪修」存進梯度表，後者才動權重。

loss 曲線

step	loss	lr	梯度範數	秒
1	8.8149	3.000e-05	0.8127	0.4
200	5.3237	2.992e-03	0.3945	5.7
500	4.2052	2.875e-03	0.3919	13.6
1000	3.6166	2.408e-03	0.3512	26.8
1500	3.1605	1.723e-03	0.3512	40.0
2000	3.0630	1.018e-03	0.3594	53.1
2500	2.9718	4.932e-04	0.3764	66.2
3000	2.7806	3.000e-04	0.3886	79.4

8.81 → 2.78，79 秒。lr 的形狀是 warmup（前 100 步爬升）接 cosine 衰減。

完整曲線每 20 步一筆：`traces/train_log.txt`（152 行）

階段 4：生成

```
python generate.py --prompt "機器學習是"
```

實際輸出

機器學習是一項重要的領域，即將資料能夠從大量資料中學習和推理。
機器學習可以用於學習、自然語言處理和自然語言生成等各種任務。

台灣的天氣如今，在這裡有著令人無法抗衰老的環境和繁華性災難。
這些災難事件可以用於對當地居民群落和探討。

貓是一種常見的寵物，並且常常會受到許多人關注和感悟。
狗通常很快地奔跑、游泳、跳傘……

第一段語意通順、術語正確。後兩段語法沒問題但語意會飄——這就是 475 萬參數、吃 424 萬 token 該有的水準。

（機器學習 被 BPE 合併成單一 token，所以模型對它的處理特別穩。）

階段 5：權重與 tokenizer 綁定

```
python tests/test_tokenizer_binding.py
```

實際輸出

① 正確的 tokenizer loss = 3.5754
② id 對應被打亂 loss = 12.0569

換算成 perplexity（等效於在幾個選項中亂猜）：

正確 tokenizer 35.7

打亂之後 : 172287.4

完全隨機的模型 : 6400.0

③ 詞表大小不同 -> RuntimeError: size mismatch（安全，馬上知道出事）

④ 擴充 6400 -> 6450，同一句話 loss 幾乎不變

用錯 tokenizer 比完全沒訓練過的模型還糟 27 倍，而且不會報錯。所以 `model.save()` 會把 tokenizer 的指紋一起存進去，載入時比對。

產出的檔案

檔案	行數	大小	看什麼
<code>gradcheck.txt</code>	18	0.9 KB	九層的驗證總表，可直接貼進簡報
<code>model_summary.txt</code>	32	1.1 KB	參數量分佈與所有超參數
<code>bpe_training.txt</code>	54	4.0 KB	詞表怎麼從 5,227 長到 6,400
<code>train_log.txt</code>	152	8.6 KB	每 20 步的 loss / lr / 梯度範數
<code>inference.txt</code>	456	28.6 KB	一次推論的完整前向（沒有反向）
<code>train_step_0001.txt</code>	926	58.8 KB	第 1 步的完整前向 + 反向 + 更新
<code>train_step_3000.txt</code>	925	58.8 KB	最後一步，可跟第 1 步對照
<code>out/model.pt</code>	—	18.6 MB	訓練好的權重
<code>out/tokenizer_bpe.json</code>	—	65 KB	詞表與合併規則

怎麼讀 926 行的追蹤檔

不要從頭讀。先看骨架，再跳到想看的地方。

骨架（行號可直接跳）

```
8  這一批的資料          ← 這批文字長什麼樣
19 前向傳播
25  embed · forward (查表)
45  ===== block0 ===== ← 每個 block 約 100 行
474 softmax + cross-entropy · forward
493 softmax + cross-entropy · backward ← p - y 在這裡
510 反向傳播
776  ===== block0 · backward =====
851  embed · backward (scatter-add) ← 兩條梯度路徑的拆解
889 AdamW 更新 (第 1 步)      ← 權重真正被改的地方
917 這一步結束
```

`block1` / `block2` / `block3` 的結構跟 `block0` 一模一樣，看一個就夠。

導覽：五個最值得看的片段

① 第 25 行 — 查表就是查表

公式: $x = E[\text{ids}]$

等價於 $x = \text{one_hot}(\text{ids}) @ E$ ，只是跳過了乘以 0 的部分

`ids` `shape (64, 128)`

`x` `shape (64, 128, 256)`

位置	查哪一列	E[id] 的前 4 維			
t=0	id=4	+0.01647	-0.04764	+0.02504	+0.00472
t=1	id=5868	-0.00623	+0.02665	-0.00391	-0.01012

>> 這一批用到 2036 個不同的 token，詞表共 6400 個。

>> 剩下 4364 列這一步完全沒被碰到——反向時它們的梯度會是 0。

前向沒有任何乘法，就是索引。記住 `2036 / 6400` 這個數字，第 ④ 點會用到。

② 第 493 行 — 整條鏈唯一知道答案的地方

公式: $dz = (p - y) / N$

token id	p	y	$dz = (p-y)/N$	作用
4656	+0.00048	+0.00000	+5.920e-08	壓下去
220	+0.00046	+0.00000	+5.575e-08	壓下去
5868	+0.00026	+1.00000	-0.00012	拉上來（正解）

正解那一格 $y = 1$ ，所以 dz 是**負的**。更新時 $E \leftarrow E - \eta dz$ ，負負得正，分數被推高。其他格全是正的，分數被壓低。

這一行就是整個訓練的全部監督訊號。往下每一層都只是機械式的微分。

③ 第 851 行 — scatter-add，以及它不是唯一的來源

公式: $dE[v] += \sum_{\{t : id_t = v\}} dx[t]$

這一系列的梯度其實是兩條路加起來的：

	來源	$dE[5][0]$	有幾列非零
輸入側（本步 scatter-add）		+0.00125	2036 / 6400 ← 稀疏
輸出側（weight tying）		-0.00420	6400 / 6400 ← 稠密
合計 $dE[5][0]$		-0.00295	6400 / 6400

2036 / 6400 正是第 ① 點那個數字——輸入側只碰得到出現過的 token。但因為 E 同時是分類器權重，softmax 會碰到**每一列**，所以總梯度是稠密的。

注意兩條路的符號還相反（+0.00125 vs -0.00420），合計後變號。

④ 第 889 行 — 位移恰好等於 lr

更新前 p	+0.00388	+0.04323	-0.00344	+0.01698
梯度 g	-1.290e-06	+8.668e-05	-5.620e-05	-6.518e-06
$\hat{m}$	-1.290e-06	+8.668e-05	-5.620e-05	-6.518e-06
$\sqrt{\hat{v}}$	+1.290e-06	+8.668e-05	+5.620e-05	+6.518e-06
$\hat{m}/(\sqrt{\hat{v}}+\epsilon)$	-0.99231	+0.99988	-0.99982	-0.99847
位移 Δ	+2.977e-05	-3.000e-05	+2.999e-05	+2.995e-05
lr				3.000e-05

看第 2 行和第 4 行：梯度從 1.29×10^{-6} 到 8.67×10^{-5} ，差了 67 倍。但位移全都是 $\pm 3 \times 10^{-5}$ ，一模一樣。

因為第一步時 $\hat{m} = g$ 、 $\sqrt{\hat{v}} = |g|$ ，相除必定是 ± 1 ：

$$\frac{\hat{m}_1}{\sqrt{\hat{v}_1}} = \frac{g}{|g|} = \text{sign}(g)$$

Adam 讓所有參數走一樣遠，差別只在方向。

⑤ 對照 train_step_3000.txt

同一個位置的數字，訓練 3000 步之後：

```
diff <(sed -n '493,500p' traces/train_step_0001.txt) \  
    <(sed -n '493,500p' traces/train_step_3000.txt)
```

第 1 步時正解的機率是 0.00026（幾乎是 1/6400 的隨機猜測），第 3000 步會明顯高出來。這是最直接的「模型學到東西了」的證據。

重跑

```
rm -rf out traces  
python tests/test_layers.py  
python train.py --tokenizer bpe --vocab 6400 --steps 3000 \  
    --dim 256 --layers 4 --heads 4 --seq 128 --batch 64 \  
    --trace-steps 1,3000  
python generate.py --prompt "機器學習是"  
python tests/test_tokenizer_binding.py
```

固定 seed（預設 42），所以數字可以完全重現。