

llm-from-scratch 教學文件

從零手刻 Transformer

每一條公式與反向傳播都自己寫

github.com/GarfieldHuang/llm-from-scratch

2026-09-06

目錄

1. 符號說明
2. 全景圖
3. tokenizer
4. embedding
5. 反向傳播
6. adamw
7. 常見誤解
8. 權重與tokenizer綁定
9. rmsnorm
10. attention
11. ffn
12. 完整執行紀錄

符號說明

其他文件裡用到的所有符號都在這裡。**建議先看這份**，尤其是 $\odot$ 和 $@$ 那一節——這兩個都叫「乘」，但完全是兩回事，混淆的話後面每條公式都會讀錯。

可執行的對照示範：

```
python tools/demo_operators.py
```

最容易混淆的兩個： $\odot$ 與 $@$

$\odot$ 逐元素相乘 (Hadamard product)

$$(A \odot B)_{ij} = A_{ij} \times B_{ij}$$

位置對位置相乘，形狀不變。

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$$
$$A \odot B = \begin{bmatrix} 1 \times 5 & 2 \times 6 \\ 3 \times 7 & 4 \times 8 \end{bmatrix} = \begin{bmatrix} 5 & 12 \\ 21 & 32 \end{bmatrix}$$

左上角那格 = $1 \times 5 = 5$ 。每一格只跟「同一格」的對手相乘，跟其他格完全無關。

$@$ 矩陣乘法 (matrix multiplication)

$$(A @ B)_{ij} = \sum_k A_{ik} \times B_{kj}$$

左邊的「列」跟右邊的「行」做點積。



$$A @ B = \begin{bmatrix} 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 \\ 3 \times 5 + 4 \times 7 & 3 \times 6 + 4 \times 8 \end{bmatrix} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$$

左上角那格 = $1 \times 5 + 2 \times 7 = 19$ 。用到了一整列和一整行，也就是所有維度。

同樣的輸入，結果完全不同

	$A \odot B$	$A @ B$
左上角	5	19
算法	一對一相乘	一整列 · 一整行
形狀	必須相同，輸出也相同	$(m,k) @ (k,n) \rightarrow (m,n)$
會不會混合維度	不會	會

為什麼「會不會混合維度」是關鍵



⊙ 的每一條線都是平行的，資訊不會橫向流動。@ 的每個輸出都吃進了所有輸入。

這決定了它們在模型裡的角色：

符號	出現在哪	做什麼
@	Linear : $y = x @ W^T$	把 d 維換成另外 d_out 維
@	Attention : QK^T	每個位置跟每個位置做點積
@	輸出層 : hE^T	隱藏狀態跟每個詞向量做點積
⊙	RMSNorm : $y = g ⊙ \hat{x}$	每個維度乘上自己的縮放係數
⊙	SwiGLU : $m = s ⊙ u$	閘門：每個維度各自決定放行多少
⊙	RoPE : $x ⊙ \cos$	每個維度乘上自己的旋轉係數

⊙ 永遠不會把不同維度的資訊混在一起。所以模型的「學習能力」幾乎全部來自 @，⊙ 只負責調整強度。

這也解釋了為什麼「疊很多個 ⊙」沒有用——不管乘幾次，維度 1 永遠只影響維度 1。

形狀規則

x shape (4, 8)

$x @ W.T \rightarrow (4, 3)$ $(4, 8) @ (8, 3)$ 最後一維被換掉了

$x ⊙ g \rightarrow (4, 8)$ $(4, 8) ⊙ (8,)$ 形狀完全不變

$x ⊙ g$ 用到了**廣播** (broadcasting)：g 只有 8 個數字，會自動複製 4 份，對 x 的每一列各做一次逐元素相乘。

反向傳播的規則也不一樣

先給結論，下面逐元素推導：

$$y = a ⊙ b \implies \frac{\partial L}{\partial a} = \frac{\partial L}{\partial y} ⊙ b, \quad \frac{\partial L}{\partial b} = \frac{\partial L}{\partial y} ⊙ a$$

$$y = x @ W^T \implies \frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} @ W, \quad \frac{\partial L}{\partial W} = \left(\frac{\partial L}{\partial y} \right)^T @ x$$

差別只有一句話：

⊙：一個輸入只影響**一個**輸出 → 不用加總，直接乘 @：一個輸入影響**多個**輸出 → 要把所有路徑**加起來**

可執行的逐元素推導：

```
python tools/demo_backward.py
```

先講清楚：dy 是哪來的

下面的推導裡會出現 $dy_i = 10$ 這種數字。**那是任意編的**，不是算出來的。

在示範裡任意，是故意的。 backward 公式的正確性，要求它對**任何** dy 都成立——這正是各層能自由組合的前提。所以測試時餵隨機值才是對的作法：

```
# scratch/gradcheck.py
dy = torch.randn(y0.shape) # 隨機的上游梯度
dx = layer.backward(dy)     # 用它測 backward
```

如果 backward 只對某些 dy 才對，那它就是錯的。（這裡挑 10、100、1000 只是為了讓每個數字的來源追得出來——看到 1100 就知道是 100×11 。）

在真實模型裡，dy 是從上一層傳下來的。 追蹤檔的實際數字：

層	$\ dy\ $ （上游進來）	$\ dx\ $ （往下傳出去）
block3	0.006687	0.007068
block2	0.007068	0.007881
block1	0.007881	0.012044
block0	0.012044	0.297985

每一層的 dx 就是下一層的 dy，數字完全相同。這就是「接力」的實際樣子。

（最後那個 $0.012 \rightarrow 0.298$ 的大跳躍，是 RMSNorm 除以 $r \approx 0.02$ 造成的放大。見 [08-rmsnorm](#)。）

一直往上追，源頭只有一個。 追到最頂端就沒有「上一層」了：

$$\frac{\partial L}{\partial \mathbf{z}} = \mathbf{p} - \mathbf{y}$$

這裡不是從別人那裡拿來的，是**算出來的**—— $\mathbf{p}$ 是模型的預測， $\mathbf{y}$ 是正確答案。

$dz = p - y$ ← 唯一的源頭，只有這裡有「對錯」的資訊

↓ `lm_head.backward`

↓ `final_norm.backward`

↓ `block3 ... block0` 每一步都只是「翻譯」

dx = 送到 `embedding` 的修正單

推導一： $y = a \odot b$

先看純量版本。設 $a_1 = 2$ 、 $b_1 = 7$ ：

$$y_1 = a_1 \times b_1 = 14$$

把 a_1 加 1， y_1 會加多少？加 $b_1 = 7$ 。所以

$$\frac{\partial y_1}{\partial a_1} = b_1$$

鏈鎖律接上去（設上游給的 $dy_1 = 10$ ）：

$$\frac{\partial L}{\partial a_1} = \underbrace{\frac{\partial L}{\partial y_1}}_{dy_1=10} \times \underbrace{\frac{\partial y_1}{\partial a_1}}_{b_1=7} = 70$$

逐元素版本只是把這件事重複 n 次——因為 a_1 只影響 y_1 ，完全不碰 y_2 、 y_3 ：

維度	dy_i	b_i	$\partial L / \partial a_i = dy_i \times b_i$
1	10	7	$10 \times 7 = 70$
2	100	11	$100 \times 11 = 1100$
3	1000	13	$1000 \times 13 = 13000$

為什麼公式裡出現的是 b ？因為 b 是放大倍率。 $b_2 = 11$ 代表 a_2 動一點點， y_2 會動 11 倍——梯度傳回來當然要乘 11。

推導二： $y = x @ W^T$

用 $x = [2 \ 3 \ 5]$ 、 $W = [1 \ 0 \ -1; 4 \ 2 \ 0]$ ，先完全展開：

$$y_1 = x_1 W_{11} + x_2 W_{12} + x_3 W_{13} = 2 \cdot 1 + 3 \cdot 0 + 5 \cdot (-1) = -3$$

$$y_2 = x_1 W_{21} + x_2 W_{22} + x_3 W_{23} = 2 \cdot 4 + 3 \cdot 2 + 5 \cdot 0 = 14$$

關鍵： x_i 同時出現在 y_1 和 y_2 裡面。這是跟 $\odot$ 最大的差別。

所以要把兩條路加起來（設 $dy = [10 \ 100]$ ）：

$$\frac{\partial L}{\partial x_1} = dy_1 \frac{\partial y_1}{\partial x_1} + dy_2 \frac{\partial y_2}{\partial x_1} = dy_1 W_{11} + dy_2 W_{21} = 10 \times 1 + 100 \times 4 = 410$$

$$\frac{\partial L}{\partial x_2} = 10 \times 0 + 100 \times 2 = 200, \quad \frac{\partial L}{\partial x_3} = 10 \times (-1) + 100 \times 0 = -10$$

為什麼是 $dy @ W$ 而不是 dy^T ？

看上面： x_j 配到的是 W_{1j} 和 W_{2j} ——也就是 **W 的第 j 行 (column)**。而矩陣乘法 $dy @ W$ 取的正好就是 W 的行。所以不用轉置。

$$\frac{\partial L}{\partial x} = dy @ W = [410 \quad 200 \quad -10]$$

為什麼 $\partial L / \partial W$ 要轉置

W_{ij} 只出現在 y_i 裡面，而且乘的是 x_j 。所以

$$\frac{\partial L}{\partial W_{ij}} = dy_i \times x_j \quad (\text{沒有加總，只有一項})$$

W_{ij}	dy_i	x_j	結果
W_{11}	10	2	20
W_{12}	10	3	30
W_{13}	10	5	50
W_{21}	100	2	200
W_{22}	100	3	300
W_{23}	100	5	500

「每個 dy_i 乘上每個 x_j ，排成一個矩陣」——這就是**外積**：

$$\frac{\partial L}{\partial W} = dy^T @ x = \begin{bmatrix} 20 & 30 & 50 \\ 200 & 300 & 500 \end{bmatrix}$$

忘記的時候：用形狀反推

實務上最好用的記憶法。**梯度的形狀永遠跟被微分的東西一樣**：

$\partial L / \partial x$ 要是 (1,3) -> $dy(1,2) @ W(2,3)$ 只有這樣接得起來

$\partial L / \partial W$ 要是 (2,3) -> $dy^T(2,1) @ x(1,3)$

把形狀寫出來，答案通常**只有一種排法**。

為什麼 @ 的反向也是矩陣乘法

因為矩陣乘法本身就是「乘完再加總」，而反向要做的正好是**路徑加總**——兩件事剛好同構。

`tools/demo_backward.py` 用有限差分驗證了全部四條規則，誤差 $10^{-6} \sim 10^{-7}$ 等級。

其他符號

運算

符號	名稱	意思
$\cdot$	點積	兩個向量對應相乘後加總，得到一個 純量 ： $a \cdot b = \sum_k a_k b_k$
$\otimes$	外積	兩個向量產生一個 矩陣 ： $(a \otimes b)_{ij} = a_i b_j$
A^T	轉置	列與行互換： $(A^T)_{ij} = A_{ji}$
$\sum_k$	求和	對指標 k 把所有項加起來
$\ x\ $	範數	向量長度： $\sqrt{\sum_k x_k^2}$
$\leftarrow$	賦值	「用右邊的值取代左邊」，不是等式

• 和 @ 的關係：@ 就是把 • 做很多次。 $(A @ B)_{ij}$ 就是「A 的第 i 列」•「B 的第 j 行」。

微分

符號	意思
$\partial L / \partial x$	L 對 單一個數字 x 的偏導數。白話：「把 x 動一丁點，L 會變多少」
$\partial L / \partial \mathbf{x}$	對 整個向量 微分（粗體代表向量）。結果跟 $\mathbf{x}$ 同形狀，每個元素各是一個偏導數
$f'(z)$	單變數函數的導數
δ_{ij}	Kronecker delta： $i = j$ 時為 1，否則為 0

程式碼裡為了簡潔， $\partial L / \partial \mathbf{x}$ 一律寫成 `dx`。

函數

符號	定義
$\sigma(z)$	sigmoid： $1/(1 + e^{-z})$ ，把任意實數壓到 (0,1)
$\text{SiLU}(z)$	$z\sigma(z)$ ，也叫 Swish
$\text{softmax}(z)_i$	$\exp(z_i) / \sum_k \exp(z_k)$ ，把一排分數變成機率（和為 1）
$\text{mean}(x)$	平均值

形狀與維度

符號	意思	本專案的典型值
B	batch size，一次處理幾段文字	64
T	序列長度，一段文字幾個 token	128
d	模型維度（hidden size）	256
h	attention head 數	4
d_head	每個 head 的維度， $= d / h$	64
d_ff	FFN 的中間維度	672
V	詞表大小	6400
N	一個 batch 裡有效的預測位置數	$B \times T$

張量形狀寫成 (B,T,d)，最後一維永遠是「特徵維度」。

常見的讀法陷阱

① W^T 出現在哪一邊

程式碼寫 `x @ W.T`，因為 PyTorch 的慣例是 W 的形狀為 (d_out, d_in)。所以要先轉置才對得上。數學文獻常寫成 Wx （W 在左），兩者是同一件事，只是排列不同。

② $\partial L / \partial W$ 的形狀

永遠跟 W 一樣。梯度是「每個參數各自的斜率」，所以有幾個參數就有幾個梯度。

③ $\leftarrow$ 不是 $=$


$$\theta \leftarrow \theta - \eta g$$


這是「更新」：用右邊算出來的值取代左邊。寫成 $\theta = \theta - \eta g$ 在數學上是個無解的方程式。

全景圖

一句話進去，到權重被改動，中間到底發生了什麼。

完整流程






實線是前向，虛線是反向。注意那條回到最上面的迴圈——訓練就是這個迴圈跑幾千次。

第 0 步：文字怎麼變成 id

上圖第二格的「tokenizer」其實是一個**獨立於模型之外**的階段。它在訓練開始前就先跑完，之後整個訓練過程都不會再變動。



這裡沒有任何學習，純粹是貪婪的頻率統計。沒有梯度、沒有神經網路。

$$|\mathcal{V}| = |\mathcal{V}_0| + M$$

實測：

起始詞表 3,653 (4 特殊 + 3,649 字元)

目標 6,400 → 需要合併 2,747 次

$$3,653 + 2,747 = 6,400$$

它為什麼是全景圖的一部分——**tokenizer 決定了模型的架構參數**：

決定了什麼	為什麼
詞表大小 $ \mathcal{V} $	直接等於 embedding 的列數
embedding 參數量	$ \mathcal{V} \cdot d$ ，這裡是 $6400 \times 256 = 1.6\text{M}$
logits 張量大小	$B \times T \times \mathcal{V} $ ，訓練時最大的中間張量
序列長度	BPE 讓序列比字元級短約 30%，而 attention 是 $O(n^2)$ ，計算量差更多

切分效果的直接影響（同一個模型、同一份語料）：

原文 機器學習是人工智慧的一個分支

字元級 ['機', '器', '學', '習', '是', '人', '工', '智', '慧', '的', '一', '個', '分', '支'] 14 tokens

BPE ['機器學習', '是', '人', '工智慧', '的一個', '分', '支'] 7 tokens


機器學習 變成一個 token。這代表模型不必再從四個字元學會它們常常一起出現，那件事在 tokenizer 階段就處理掉了。

細節見 02-tokenizer，程式碼在 [tokenizer/bpe.py](#)。

注意：換 tokenizer 之後，loss 的數值**不能直接互相比較**。字元級 3,195 詞表跑出 loss 2.24，BPE 6,400 詞表跑出 2.76，但後者每個 token 攜帶的資訊量更大，猜對更難。要公平比較得換算成 bits-per-character：

$$\text{bpc} = \frac{L \cdot N_{\text{token}}}{N_{\text{char}} \cdot \ln 2}$$

一個 Block 的內部



寫成公式：

$$\mathbf{h} = \mathbf{x} + \text{Attention}(\text{RMSNorm}(\mathbf{x}))$$

$$\mathbf{y} = \mathbf{h} + \text{FFN}(\text{RMSNorm}(\mathbf{h}))$$

三件事要記住：

1. 順序是 **Norm** → **Attention** → **Norm** → **FFN**。不是 FFN 先。
2. 那兩個 + 是殘差。前向 $y = x + f(x)$ ，反向

$$\frac{\partial L}{\partial \mathbf{x}} = \frac{\partial L}{\partial \mathbf{y}} + f' \left(\frac{\partial L}{\partial \mathbf{y}} \right)$$

那個孤零零的 $\partial L / \partial y$ 是「直達路徑」，梯度可以完全不衰減地穿過去。沒有殘差的話，20 層以上基本訓不動。

3. **Attention 橫向**，**FFN 縱向**。Attention 是唯一讓不同位置互通的地方；FFN 對每個位置各做各的。

資料的形狀怎麼變

以 $B = 8$ 、 $T = 64$ 、 $d = 256$ 、 $|V| = 6400$ 為例：

階段	形狀	說明
token ids	$(8, 64)$	整數
查表後	$(8, 64, 256)$	每個位置一個 256 維向量
每個 Block 之後	$(8, 64, 256)$	形狀不變 ，只是內容被加工
logits	$(8, 64, 6400)$	每個位置對整個詞表的分數
loss	$()$	一個純量

注意 logits 那一步：

$$8 \times 64 \times 6400 = 3.27 \times 10^6$$

這通常是整個模型**最大的中間張量**，訓練時的記憶體大戶。

參數住在哪裡

跑 `python train.py` 會印出來，例如：

模型結構

=====	
embedding	204,480
block0	47,232
block1	47,232
final_norm	64
lm_head (與 embedding 共用)	0

總計	299,008
embedding 佔比	68.4%

小模型的 embedding 佔比會很誇張，因為兩者的量級是

$$\underbrace{|\mathcal{V}| \cdot d}_{\text{embedding}} \quad \text{vs} \quad \underbrace{O(d^2)}_{\text{每一層}}$$

而小模型的 $|\mathcal{V}| \gg d$ 。真實的大模型 d 大得多，embedding 佔比會降到 5% 以下。

前向與反向的對稱

每一層的 `backward` 都在回答同一個問題：「我的輸出該怎麼動」→「我的輸入該怎麼動」。

層	前向	反向
Linear	$y = xW^T$	$\partial L / \partial x = \partial L / \partial y W, \partial L / \partial W = (\partial L / \partial y)^T x$
Embedding	$x = E_v$ (gather)	$\partial L / \partial E_v = \sum_i \text{id}_i : \text{id}_i = v G_i$ (scatter-add)
RMSNorm	$\hat{x} = x / r$	$1/r(a - \hat{x} \text{mean}(a \odot \hat{x}))$
RoPE	旋轉 $+\theta$	旋轉 $-\theta$
softmax + CE	$p = \text{softmax}(z)$	$\partial L / \partial z = p - y$
殘差 $y = x + f(x)$	分岔	相加

最後一列是通則：一個張量被用了 k 次，它的梯度就是那 k 條路的總和。

$$\frac{\partial L}{\partial \mathbf{x}} = \sum_{i=1}^k \frac{\partial L}{\partial \mathbf{x}} \Big|_{\text{第 } i \text{ 條路}}$$

下一步

- 想知道詞表大小怎麼定 → [02-tokenizer](#)

- 想知道 embedding 怎麼被訓練 → 03-embedding
- 想跟著梯度走一遍 → 04-反向傳播

詞表大小是怎麼決定的

「minimind 的詞表 6400 個 token，這個數字是哪來的？」

不是算出來的，是你自己挑的停止條件。

$$|\mathcal{V}| = \underbrace{|\mathcal{V}_0|}_{\text{起始符號數}} + \underbrace{M}_{\text{合併次數}}$$

BPE 每合併一次，詞表就多一個。想要 $|\mathcal{V}| = 6400$ ，就合併到總數變成 6400 為止。

實際跑一次的數字

```
python tests/test_bpe.py
```

詞塊 183,640 個（相異 74,440 個），字元 546,000 個


起始詞表 3,653（4 特殊 + 3,649 字元）

目標 6,400 → 需要合併 2,747 次

$$3,653 + 2,747 = 6,400$$

看最後一行。就這麼直接。

BPE 在做什麼



沒有任何學習、沒有梯度、沒有神經網路。純粹是貪婪的頻率統計。

合併過程長什麼樣

`traces/bpe_training.txt` 會記下每一次合併：

```
合併 #1      ('可', '以') 出現 2,362 次 -> 新 token '可以'    詞表 3,654
合併 #2      ('我', '們') 出現 1,988 次 -> 新 token '我們'    詞表 3,655
...
合併 #1000   ('歌', '詞') 出現    40 次 -> 新 token '歌詞'    詞表 4,653
合併 #2000   ('排', '放') 出現    21 次 -> 新 token '排放'    詞表 5,653
```

注意**出現次數一路遞減**：2362 → 1988 → ... → 40 → 21。

這給了一個很實用的判斷：**如果最後幾次合併的次數已經降到個位數，代表詞表開太大了**，那些 token 學不到什麼東西。反過來，如果停下來的時候 次數還有好幾百，代表還可以再擴。

效果

500 段，共 140,502 字元

字元級 140,502 tokens 1.000 token/字

BPE 99,202 tokens 0.706 token/字

BPE 讓序列短了 29.4%

切分對照：

原文 機器學習是人工智慧的一個分支

字元級 ['機', '器', '學', '習', '是', '人', '工', '智', '慧', '的', '一', '個', '分', '支']

BPE ['機器學習', '是', '人', '工智慧', '的一個', '分', '支']

機器學習 變成一個 token 了。序列變短的直接好處：

- 同樣的 context window 能裝更多內容
- Attention 是 $O(n^2)$ ，序列短一半，注意力的計算量剩四分之一

為什麼順序不能亂

編碼的時候要**照訓練時學到的順序**套用合併：

'機器學習' 這個 token 存在的前提，是 '機器' 和 '學習' 已經先被合併出來了。

所以 `bpe.py` 裡每個合併都記了 `rank`（第幾次學到的），編碼時永遠先套 rank 最小的。

這份實作與生產級的差別

	這裡	GPT-2 / Qwen / minimind
起始符號	語料裡的 字元	256 個 byte
OOV	用 <code><unk></code>	不可能有（任何字都能拆成 byte）
追蹤檔可讀性	每個符號都是你認得的字	生僻字會變成看不懂的 byte 碎片

byte-level 的代價，在前面的實驗裡量過：用簡體訓的 tokenizer 去吃繁體語料時，「這」會被拆成兩個 byte 碎片，序列長度膨脹 1.67 倍。因為那些繁體字**根本不在詞表裡**。

這也是為什麼換語言、換領域時，tokenizer 常常得重訓。

一個容易忽略的連結

詞表大小直接決定了 embedding 的參數量：

$$|\theta_{\text{embed}}| = |\mathcal{V}| \times d$$

$6400 \times 768 = 4,915,200$ 。詞表開兩倍，embedding 就大兩倍。

而且因為 weight tying，同一個矩陣還兼任輸出層——所以詞表大小也直接決定了最後那個 logits 張量有多大：

$$\text{logits} \in \mathbb{R}^{B \times T \times |\mathcal{V}|}$$

那通常是訓練時**最大的中間張量**。以 $B=64$ 、 $T=128$ 、 $|\mathcal{V}|=6400$ 為例，光這一個張量就有 5.24×10^7 個數字。

詞表大小不只是 tokenizer 的參數，它同時是模型的架構參數。

Embedding 與 scatter-add

對應程式碼：`scratch/embedding.py`

它不是資料，是權重

最容易誤會的一點：E 看起來像一張查詢表，所以直覺會把它歸類成「輸入」。

但它在 `model.params()` 裡跟 `q_proj.W` 排在一起，用同一個 optimizer、同樣的 η 、同樣的更新規則。跑 `train.py` 印出的參數表就是證據：

```
model.embed.E          204,480    ← 就是它
block0.attn.q_proj.W    16,384
block0.ffn.gate_proj.W  43,776
...
optimizer 拿到 20 個參數張量
```

「embedding 有一套自己的訓練方法」——這件事不存在。

查表 = one-hot 矩陣乘法

$$\mathbf{x} = \text{onehot}(v) E, \quad E \in \mathbb{R}^{V \times d}$$

`onehot(v)` 只有第 v 個元素是 1、其餘全 0。乘出來就是把 E 的第 v 列抄出來：

$$x_j = \sum_{k=1}^V \text{onehot}(v)_k E_{kj} = E_{vj}$$

既然 $(V-1)/V = 99.98\%$ 的乘法都是「乘以 0」，實作當然直接索引：

```
x = E[ids]
```

兩者結果逐位元相同，實測查表快 20 倍以上、省 8 倍記憶體。

把它看成矩陣乘法很重要——因為反向就是從這裡推出來的。

反向：scatter-add



把整批寫成矩陣形式 $X = OE$ （ O 是常數 one-hot 矩陣），套用線性層的標準結果：

$$\frac{\partial L}{\partial E} = O^\top G, \quad G = \frac{\partial L}{\partial X}$$

$O^\top$ 的第 v 列，在「第 t 個位置的 id 等於 v 」的地方是 1，其餘是 0。展開得到：

$$\frac{\partial L}{\partial E_v} = \sum_{t: \text{id}_t=v} G_t$$

白話：把每個位置的梯度，加回它當初查表的那一列；同一列有多筆就相加。



由此直接得到兩個常被誤會成「特殊規則」的性質——其實都只是算出來的結果：

現象	為什麼
同一個 token 出現 k 次 → 那一列收到 k 筆梯度 相加	$O^\top$ 那一列有 k 個 1，矩陣乘法自然就加起來了
沒出現過的 token → 梯度是 0	$O^\top$ 那一列全是 0

追蹤檔裡的實際數字

embed . backward (scatter-add, 輸入側)

公式: $dE[v] += \sum_{t: id_t = v} dx[t]$

「id 4」在這一批出現 27 次

看第 0 維，這 27 筆修正單相加：

位置 1 $dx[0] = +1.09540625e-02$

位置 12 $dx[0] = +5.40754059e-03$

...

這 27 筆相加 = $+1.67316496e-02$

但梯度其實有兩條路

這是最容易混淆的地方。因為 weight tying (E 同時是輸出層的權重)，它會收到**兩份**梯度。

輸出側那條有封閉解。因為 $\text{logits}_t = \mathbf{h}_t \mathbf{E}^T$ ：

$$\left. \frac{\partial L}{\partial E_v} \right|_{\text{out}} = \frac{1}{N} \sum_t (p_t[v] - y_t[v]) \mathbf{h}_t$$

實測：

來源	$\partial L / \partial E_v[0]$	有幾列非零
輸入側 (scatter-add)	+0.01673	272 / 3195 ← 稀疏
輸出側 (weight tying)	+0.00500	3195 / 3195 ← 稠密
合計	+0.02174	3195 / 3195

	來自哪裡	稀疏還是稠密
輸入側	查表這條路，backprop 傳回來的	稀疏，只有出現過的 token
輸出側	$\text{logits} = \mathbf{h} \mathbf{E}^T$ ，softmax 那條路	稠密，每一步每一列都被碰到

所以「embedding 的梯度是稀疏的」這句話，**在有 weight tying 的模型上並不成立**。

想親眼驗證：把 `TinyLM(..., tie_weights=False)` 跑一次，非零列就會剩下 272。

注意這裡的點積是「隱藏狀態 · 詞向量」，**不是**「詞向量 · 詞向量」。訓練過程中從來沒有計算過任何兩個詞向量之間的相似度——cosine 只是我們事後檢查用的量尺。

「離散的 id 怎麼微分？」

不對 id 微分。

	是什麼	離散/連續	微分嗎
id = 4	資料	離散	不用，也不能
$E_{4,0} = -0.0153$	參數	連續實數	對它微分

梯度問的是：

$$\frac{\partial L}{\partial E_{4,0}} = \lim_{\varepsilon \rightarrow 0} \frac{L(E_{4,0} + \varepsilon) - L(E_{4,0} - \varepsilon)}{2\varepsilon}$$

這個問題跟 id 是不是離散**完全無關**。id 只決定「哪些數字參與計算」。

沒參與的，斜率算出來自然是 0：

$$f(a, b, c) = a + b \implies \frac{\partial f}{\partial c} = 0$$

不是「不能微分」，是「算出來就是 0」。

有限差分實測（ $\varepsilon = 10^{-3}$ ，句子含重複的「在」）：

格子	$(L_+ - L_-) / 2\varepsilon$	公式	說明
$E_{2,0}$ （在）	0.246048	0.246000	查兩次，斜率加倍
$E_{0,0}$ （貓）	0.123024	0.123000	查一次
$E_{1,0}$ （狗）	0.000000	0.000000	沒被查到

「狗」那一列 $L(w+\varepsilon)$ 和 $L(w-\varepsilon)$ **完全相等**——那個數字沒參與計算，動它 L 不會變。

`tests/test_layers.py` 對這一層的驗證結果：相對誤差 6.80×10^{-14} 。

延伸：離散在哪裡才真的會咬人

情境	可微嗎
訓練（teacher forcing）	可微。id 是資料集給定的常數
生成（argmax / 取樣選下一個 token）	不可微，梯度在這裡斷掉


第二種才是真麻煩——這正是 RLHF / GRPO 那類「用生成結果的好壞來訓練」的方法 需要 policy gradient 之類特殊技巧的原因。

訓練 embedding 完全不碰這個問題。

反向傳播全鏈

從 p - y 一路走回 E 。

整條鏈只有一個地方知道「對錯」



只有最上面那一格含有「答案」的資訊。往下每一層都只是在做微分，不知道任務是什麼、不知道「貓是動物」。

第一棒： $\partial L / \partial z = p - y$

softmax 和 cross-entropy 分開推都很醜（會出現 $V \times V$ 的 Jacobian），但合起來推會神奇地簡化。

softmax 的 Jacobian：

$$\frac{\partial p_i}{\partial z_j} = p_i (\delta_{ij} - p_j)$$

接上 cross-entropy ($L = -\log p_y$ ， p_y 是正解那一格的機率)：

$$\frac{\partial L}{\partial z_j} = \sum_i \frac{\partial L}{\partial p_i} \cdot \frac{\partial p_i}{\partial z_j} = -\frac{1}{p_y} \cdot p_y (\delta_{yj} - p_j) = p_j - \delta_{yj}$$

整個 Jacobian 消失，只剩：

$$\frac{\partial L}{\partial \mathbf{z}} = \mathbf{p} - \mathbf{y}$$

其中 y 是正解的 one-hot。翻成白話：**正解那一格的分數要拉高，其他全部壓低。**

追蹤檔裡看到的：

token id	p	y	(p-y)/N	作用
213	0.35341	0	+0.003534	壓下去
57	0.11518	0	+0.001152	壓下去
4	0.11176	1	-0.008882	拉上來 (正解)

(除以 N 是因為 loss 對所有有效位置取了平均。)

中間每一棒都在做同一件事

每一層的 `backward` 都回答：「我的輸出該怎麼動」→「那我的輸入該怎麼動」。翻譯的方法就是用自己的導數。

Linear： $\mathbf{y} = \mathbf{x}\mathbf{W}^\top$

$$\frac{\partial L}{\partial \mathbf{x}} = \frac{\partial L}{\partial \mathbf{y}} \mathbf{W} \quad \frac{\partial L}{\partial \mathbf{W}} = \left(\frac{\partial L}{\partial \mathbf{y}} \right)^\top \mathbf{x}$$

注意 $\partial L / \partial \mathbf{x}$ 用 $\mathbf{W}$ 、 $\partial L / \partial \mathbf{W}$ 用 $\mathbf{x}$ —— 點積對其中一邊微分，得到的就是另一邊。這條規律整份程式碼裡反覆出現。

逐元素的非線性： $\mathbf{z} = \mathbf{f}(\mathbf{a})$

$$\frac{\partial L}{\partial \mathbf{a}} = \frac{\partial L}{\partial \mathbf{z}} \odot \mathbf{f}'(\mathbf{a})$$

SiLU 的導數 (用 $\sigma' = \sigma(1-\sigma)$ 推)：

$$\text{SiLU}(z) = z \sigma(z), \quad \text{SiLU}'(z) = \sigma(z)(1 + z(1 - \sigma(z)))$$

殘差： $y = x + f(x)$

$$\frac{\partial L}{\partial \mathbf{x}} = \frac{\partial L}{\partial \mathbf{y}} + f' \left(\frac{\partial L}{\partial \mathbf{y}} \right)$$

那個孤零零的 $\partial L / \partial y$ 就是「直達路徑」——梯度可以完全不衰減地穿過去。沒有殘差的話，20 層以上基本訓不動。

通則

前向分岔 $\implies$ 反向相加

x 在 SwiGLU 裡同時餵給 gate 和 up 兩路，所以

$$\frac{\partial L}{\partial \mathbf{x}} = \frac{\partial L}{\partial \mathbf{x}} \Big|_{\text{gate}} + \frac{\partial L}{\partial \mathbf{x}} \Big|_{\text{up}}$$

Attention 裡 x 餵給 Q、K、V 三路，所以三份相加。

RMSNorm：一個需要商法則的推導

前向：

$$r = \sqrt{\frac{1}{n} \sum_k x_k^2 + \varepsilon}, \quad \hat{x} = \frac{x}{r}, \quad y = g \odot \hat{x}$$

先求 r 對 x 的偏導：

$$\frac{\partial r}{\partial x_j} = \frac{1}{2} (\cdot)^{-1/2} \cdot \frac{2x_j}{n} = \frac{x_j}{n r}$$

y_i 透過兩條路依賴 x_j （分子的 x_i 、分母 r 裡的 x_j ）：

$$\frac{\partial y_i}{\partial x_j} = g_i \left[\frac{\delta_{ij}}{r} - \frac{x_i}{r^2} \cdot \frac{\partial r}{\partial x_j} \right] = g_i \left[\frac{\delta_{ij}}{r} - \frac{x_i x_j}{n r^3} \right]$$

令 $a_i = \partial L / \partial y_i g_i$ ，鏈鎖律加總後化簡：

$$\frac{\partial L}{\partial x} = \frac{1}{r} \left(a - \hat{x} \cdot \text{mean}(a \odot \hat{x}) \right)$$

$$\frac{\partial L}{\partial g} = \sum_{\text{所有位置}} \frac{\partial L}{\partial y} \odot \hat{x}$$

第二項 $-\hat{x} \text{mean}(a \odot \hat{x})$ 的意義是**把沿著 $\hat{x}$ 方向的分量扣掉**——因為 $\hat{x}$ 的長度已經被 r 固定住了，沿它自己的方向推是無效的。

Attention：含完整 softmax Jacobian

前向：

$$S = \frac{QK^\top}{\sqrt{d_{\text{head}}}}, \quad S_{ij} \leftarrow -\infty \text{ if } j > i, \quad A = \text{softmax}(S), \quad O = AV$$

除以 $\sqrt{d_{\text{head}}}$ 的理由：Q、K 各維度變異數約為 1，點積 d 個維度後變異數變成 d ，標準差 $\sqrt{d}$ 。 $d = 64$ 時分數會散到 ± 8 以上，softmax 吃到這種輸入會變得極度尖銳，梯度就消失了。

反向：

$$\frac{\partial L}{\partial A} = \frac{\partial L}{\partial O} V^\top, \quad \frac{\partial L}{\partial V} = A^\top \frac{\partial L}{\partial O}$$

這裡沒有 cross-entropy 接在後面，所以要用**完整**的 softmax 反向（逐列獨立）：

$$\frac{\partial L}{\partial S_j} = A_j \left(\frac{\partial L}{\partial A_j} - \sum_i \frac{\partial L}{\partial A_i} A_i \right)$$

括號裡那個 Σ 是「這一系列的加權平均」，每一列算一次就好。

$$\frac{\partial L}{\partial Q} = \frac{1}{\sqrt{d}} \frac{\partial L}{\partial S} K, \quad \frac{\partial L}{\partial K} = \frac{1}{\sqrt{d}} \left(\frac{\partial L}{\partial S} \right)^\top Q$$

被遮罩的位置 $A_{ij} = 0$ ，公式裡的 $A_j(\cdot)$ 自動讓梯度也是 0，**不需要另外處理**。

最後一棒：embedding 只做路由

embedding 的前向是「原封不動抄出來」，導數是 1。所以反向也是「原封不動接回去」——**它不對梯度做任何變換，只負責送回正確的列**。

$$\text{前向 gather} \iff \text{反向 scatter-add}$$

這個對稱不是設計出來的，是導數為 1 的必然結果。

一個實測現象：梯度會被放大

追蹤檔裡可以看到梯度範數逐層變化。從第 1 層傳到 embedding 時會突然放大約一個數量級。

原因是 **RMSNorm**。embedding 向量的 rms 約為 0.03：

$$\text{前向除以 } 0.03 \implies \text{放大約 } 33 \text{ 倍}$$

反向經過同一個除法時，梯度也跟著放大。（第二項 $-\hat{x}\text{mean}(a \odot \hat{x})$ 會抵消掉一部分，所以實測倍率比 $1/r$ 略小。）

怎麼確定推對了

不用 PyTorch 對答案，直接回到梯度的定義：

$$\frac{\partial L}{\partial w} \approx \frac{L(w + \varepsilon) - L(w - \varepsilon)}{2\varepsilon}$$

```
python tests/test_layers.py
```

層	最大相對誤差	測試結果
Linear (無 bias)	2.29×10^{-12}	PASS
Linear (有 bias)	2.03×10^{-12}	PASS
RMSNorm	2.13×10^{-7}	PASS
Embedding (scatter-add)	6.80×10^{-14}	PASS
TiedOutputHead	5.61×10^{-12}	PASS
SwiGLU	1.69×10^{-6}	PASS
RoPE	2.19×10^{-12}	PASS
CausalSelfAttention	3.32×10^{-7}	PASS
Softmax + CrossEntropy	7.50×10^{-8}	PASS

用**中央差分**（兩邊各推一次）而不是單邊，因為誤差是 $O(\varepsilon^2)$ 而不是 $O(\varepsilon)$ 。

ε 也不能太小——`float32` 只有約 7 位有效數字，兩個相近的數相減會被捨入誤差吃掉。所以 `gradcheck` 預設用 `float64` 跑。

反向傳播不會修改任何權重

```
model.backward(dlogits)    # 只算出「該往哪修」，存進 dw / dE
opt.step()                 # 這一行才真的改動權重
```

`backward()` 跑完之後，`E` 一個數字都沒變。梯度存在另一個張量裡。

真正動手的是 `optimizer`，而且方向**相反**（往下坡走）、步伐只有 `lr` 那麼小。詳見 05-adamw。

權重是怎麼被改的

對應程式碼：`scratch/adamw.py`

分界線

```
model.backward(dlogits)      # 算出「該往哪修」 → 存進 dE、dW
opt.step()                   # 這一行才真的改動權重
```

反向傳播從不修改權重。這兩件事之間隔著一整張梯度表。

最直覺的版本：SGD

$$\theta \leftarrow \theta - \eta g$$

「減掉梯度乘上學習率」。

為什麼是減？梯度的定義是「往哪個方向動，L 會變大」：

$$g = \frac{\partial L}{\partial \theta}$$

我們要 L 變小，所以走反方向。這就是梯度**下降**的下降。

AdamW 做了什麼

$t \leftarrow t + 1$	
$\theta \leftarrow \theta - \eta \lambda \theta$	① decoupled weight decay（與梯度無關）
$m \leftarrow \beta_1 m + (1 - \beta_1) g$	② 一階動量：梯度的移動平均
$v \leftarrow \beta_2 v + (1 - \beta_2) g^2$	③ 二階動量：梯度平方的移動平均
$\hat{m} \leftarrow \frac{m}{1 - \beta_1^t}, \quad \hat{v} \leftarrow \frac{v}{1 - \beta_2^t}$	④ bias correction
$\theta \leftarrow \theta - \eta \frac{\hat{m}}{\sqrt{\hat{v}} + \epsilon}$	⑤ 真正的更新

跟 SGD 的差別只在 ⑤：g 被換成了 $\hat{m}/(\sqrt{\hat{v}}+\epsilon)$ 。

bias correction 在做什麼：m、v 都從 0 出發，前幾步會系統性偏小。除以 $1 - \beta_i^t$ 剛好把這個偏差補回來（t 大了之後這個係數趨近 1，就沒作用了）。

關鍵性質：位移量幾乎與梯度大小無關

看 ⑤ 的分子分母：分子是梯度的平均，分母是梯度大小的平均。量級相同，相除之後大約落在 ± 1 ，於是

$$|\Delta\theta| \approx \eta$$

第一步時這件事是**精確**成立的。代入 $m_0 = v_0 = 0$ ：

$$m_1 = (1 - \beta_1)g \implies \hat{m}_1 = \frac{m_1}{1 - \beta_1} = g$$

$$v_1 = (1 - \beta_2)g^2 \implies \hat{v}_1 = \frac{v_1}{1 - \beta_2} = g^2$$

$$\frac{\hat{m}_1}{\sqrt{\hat{v}_1}} = \frac{g}{|g|} = \text{sign}(g) \implies \Delta\theta = \pm \eta$$

追蹤檔裡可以直接驗證：

	維度 1	維度 2	維度 3	維度 4
梯度 g	+0.244449	-0.286912	-0.239161	+0.236112
$\hat{m}/(\sqrt{\hat{v}}+\epsilon)$	+1.000000	-1.000000	-1.000000	+1.000000
位移 $\Delta\theta$	-0.000500	+0.000500	+0.000500	-0.000500
$ \Delta\theta /\eta$	1.0000	1.0000	1.0000	1.0000

(此處 $\eta = 5 \times 10^{-4}$ 。)

四個維度的梯度大小不同 (0.236 ~ 0.287)，位移卻**一模一樣**。

推論：總位移有上限

跑 T 步之後，任何一個參數的總位移上限大約是

$$\|\theta_T - \theta_0\| \lesssim T \cdot \bar{\eta}$$

實測驗算 (3000 步、cosine 從 3×10^{-3} 衰減)：

$$3000 \times 2.75 \times 10^{-4} \approx 0.825$$

而實測的平均位移落在 0.63 ~ 0.86——**正好卡在這個上限**。

差別只在**方向有沒有一致**：

	位移量	與初始的 cos
高頻 token	接近上限	高（方向沒怎麼變）
中頻 token	接近上限	低（轉得最多）
從沒出現的 token	接近上限	中

位移量被 Adam 封頂，真正有差別的是「動得有沒有方向」。

高頻 token 出現在幾百萬個不同上下文，每個上下文想把它拉往不同方向，加起來互相抵消——所以它走得遠，但方向沒怎麼變。

decoupled weight decay

舊的 Adam 把 $\lambda\theta$ 加進梯度裡：

$$\theta \leftarrow \theta - \eta (g + \lambda\theta)$$

問題是這樣一來 weight decay 也會被 $\sqrt{\hat{v}}$ 正規化，強度變得跟梯度大小有關，很不直覺。

AdamW 把它拆出來獨立做（上面的 ①），強度固定是 $\eta\lambda$ 。這就是 **W** 的由來。

一個實務上的坑：`torch.optim.AdamW` 預設 $\lambda = 0.01$ ，而且會套用到**所有**參數，包括 embedding 和 norm 的 gain。

生產級訓練通常把這兩類排除——因為很少拿到梯度的列會被 weight decay 慢慢磨向 0。這份程式用 `no_decay` 參數控制，預設就排除了：

```
AdamW(model.params(), lr=..., no_decay=('.g', '.E'))
```

梯度裁剪

```
opt.clip_grad_norm(1.0)
```

把所有梯度串成一個超長向量，計算它的長度：

$$G = \sqrt{\sum_{\text{所有參數}} \|g\|^2}$$

若 $G > G_{\max}$ ，**整體**按比例縮小：

$$g \leftarrow g \cdot \frac{G_{\max}}{G + 10^{-6}}$$

注意是「整體」——各參數之間的相對比例不變。這跟逐元素裁剪（clip by value）不同，後者會扭曲梯度的方向。

用途是防止偶爾出現的異常大梯度（壞資料、數值不穩）一步把模型炸掉。

learning rate schedule

```
lr = cosine_lr(step, total, base_lr, warmup=100)
```

$$\eta(t) = \begin{cases} \eta_0 \cdot \frac{t}{T_{\text{warm}}}, & t < T_{\text{warm}} \\ \eta_0 \left[\rho + (1 - \rho) \cdot \frac{1 + \cos\left(\pi \frac{t - T_{\text{warm}}}{T - T_{\text{warm}}}\right)}{2} \right], & t \geq T_{\text{warm}} \end{cases}$$

其中 ρ 是最低點的比例（預設 0.1）。

- **warmup**：一開始權重是亂數，梯度方向不可靠，這時候用大 η 容易走歪。
- **cosine 衰減**：後期要小步微調，不然會在最低點附近震盪。

`traces/train_log.txt` 記了每一步的 η ，可以直接畫成曲線。

三個最常見的誤解

做簡報時最值得講的三件事。每一條都可以用這份專案的程式碼當場驗證。

① 「embedding 是資料，不是模型的一部分」

錯。它是權重，跟 `q_proj` 完全平起平坐。

會有這個誤解，是因為 `E` 長得像一張查詢表，直覺會把它歸類成「輸入」。

怎麼當場證明

```
python train.py --steps 1 --trace-steps 1
```

看印出來的參數清單：

<code>model.embed.E</code>	204,480	← 在同一份清單裡
<code>block0.attn.q_proj.W</code>	16,384	
<code>block0.ffn.gate_proj.W</code>	43,776	
optimizer 拿到 20 個參數張量		

再看追蹤檔裡兩者的更新：

位移 <code>E[...]</code>	-0.000500	+0.000500	+0.000500	-0.000500
位移 <code>q_proj</code>	+0.000500	+0.000500	-0.000500	-0.000500

同一個 optimizer、同一套規則、同樣的 $\pm lr$ 。

為什麼直覺會漏掉它

換個框架就通了——`E` 就是「第 0 層」：

	輸入	權重	輸出
第 0 層 (embedding)	one-hot (固定資料)	<code>E</code>	詞向量
第 1 層	詞向量	<code>w_q</code> , <code>w_k</code> , <code>w_v</code> , FFN	新的向量

第 1 層的「輸入」就是第 0 層的「輸出」。梯度傳到第 1 層的輸入時不會停在那裡，它繼續往下，變成 `E` 的梯度。

② 「反向傳播會修改權重」

錯。 `backward()` 跑完，權重一個數字都沒變。

```
model.backward(dlogits)      # 只算出「該往哪修」，存進另一個張量
opt.step()                   # 這一行才真的改
```

怎麼當場證明

追蹤檔第 04 節的最後，`E` 還是原值；到第 06 節 AdamW 那裡才變。

而且方向是相反的，步伐小得多：

更新前 <code>E[...]</code>	-0.01533508	
梯度 <code>g</code>	+0.24444881	
若直接「加上梯度」	+0.22911373	← 錯誤的直覺
AdamW 實際結果	-0.01583501	← 差了 489 倍

兩層都要注意：

1. 梯度是先彼此相加存進梯度表，不是加到 `E` 上
2. `E` 真的要改的時候是減，而且要乘上很小的 `lr`

③ 「token id 是離散的，所以沒辦法微分」

混淆了兩個東西。不對 id 微分——它是資料不是參數。

	是什麼	離散/連續	微分嗎
<code>id = 4</code>	資料	離散	不用，也不能
<code>E[4][0] = -0.0153</code>	參數	連續實數	對它微分

梯度問的是：

$$\frac{\partial L}{\partial E_{4,0}} = \lim_{\varepsilon \rightarrow 0} \frac{L(E_{4,0} + \varepsilon) - L(E_{4,0} - \varepsilon)}{2\varepsilon}$$

跟 id 是不是離散完全無關。

怎麼當場證明

$$f(a, b, c) = a + b \quad (c \text{ 沒參與})$$

$$\frac{\partial f}{\partial a} = 1, \quad \frac{\partial f}{\partial c} = 0$$

$\partial f / \partial c = 0$ 不是「不能微分」，是「算出來就是 0」。

寫成矩陣就完全沒有特殊性了：

$$X = O E \quad (O \text{ 是常數 one-hot 矩陣, } E \text{ 是變數})$$

$$\frac{\partial L}{\partial E} = O^T G \quad \leftarrow \text{課本上最普通的矩陣微分}$$

$O^T G$ 展開就是

$$\frac{\partial L}{\partial E_v} = \sum_{t: \text{id}_t=v} G_t$$

剛好就是「同一列的相加、沒出現的是 0」—— **scatter-add 不是特殊規則，是矩陣乘法自然的結果。**

有限差分可以直接驗證 ($\varepsilon = 10^{-3}$)：

格子	$(L_+ - L_-) / 2\varepsilon$	公式	
$E_{2,0}$ (在)	0.246048	0.246000	查兩次，斜率加倍
$E_{1,0}$ (狗)	0.000000	0.000000	沒被查到

「狗」那一列 $L(w+\varepsilon)$ 和 $L(w-\varepsilon)$ **完全相等**—— 那個數字沒參與計算，動它 L 不會變。

延伸：離散在哪裡才真的會咬人

情境	可微嗎
訓練 (teacher forcing)	可微，id 是給定的常數
生成 (argmax / 取樣)	不可微，梯度在這裡斷掉

第二種才是真麻煩——RLHF / GRPO 需要 policy gradient 就是為了繞過它。

附：一個 bonus 誤解

「embedding 的梯度是稀疏的」—— 在有 weight tying 的模型上**不成立**。

	來源	有幾列非零
輸入側 (scatter-add)	272 / 3195	← 稀疏
輸出側 (weight tying)	3195 / 3195	← 稠密
合計	3195 / 3195	

因為 `E` 同時是輸出層的權重，softmax 要對全部 token 算分數，**每一列每一步都會被碰到**——連完全沒出現在這批資料裡的 token 也一樣。

想親眼看差別：`TinyLM(..., tie_weights=False)` 跑一次，非零列就會剩下 272。

權重與 tokenizer 是綁死的

「別人拿到這些權重做 continual pre-training，tokenizer 也要一樣才行，對嗎？」

對，而且比多數人以為的更嚴格。

不只詞表大小要一樣——**每一個 token 對應到哪個 id，都必須完全相同。**

為什麼

E 的第 v 列，存的是「訓練期間 $id = v$ 代表的那個 token」的向量。

訓練時 $id\ 4 = \text{'的'}$ $\rightarrow E[4]$ 學成了「的」的向量

換 tokenizer 後 $id\ 4 = \text{'，'}$ $\rightarrow$ 模型拿「的」的向量去理解「，」

而且因為 weight tying， E 同時是輸出層——**輸入查表跟輸出分類會一起錯亂。**

實測：錯得有多離譜

```
python tests/test_tokenizer_binding.py
```


同一個模型、同一句話，只是把 id 對應打亂（模擬「同語料但不同種子重訓的 tokenizer」）：

	loss	perplexity（等效於在幾個選項中猜）
正確的 tokenizer	3.61	37
id 對應被打亂	12.87	389,971
完全沒訓練過的模型	—	6,400（= 詞表大小）

用錯 tokenizer 比完全沒訓練過的模型還糟 61 倍。

為什麼會比隨機還差？因為隨機模型是均勻分布，至少「不確定」；而載錯 tokenizer 的模型會**很有自信地猜錯**——把高機率押在錯誤的 token 上。

三種情況，危險程度不同



| 情況 | 會怎樣 | 危險嗎 | |---|---|---| | 詞表大小不同 | `RuntimeError: size mismatch` | **不危險**——馬上就知道出事了 | | 大小相同、id 對應不同 | 安然載入、正常執行、輸出垃圾 | **非常危險**——沒有任何提示 |

第二種才是真正的坑。你會以為模型壞了、資料有問題、超參數不對，花好幾天調參，實際上只是 tokenizer 拿錯了。

防呆：把 tokenizer 的指紋存進 checkpoint

這份專案的做法：

```
# tokenizer/bpe.py
def fingerprint(self):
    s = '|'.join(self.itos) + '|'.join('%s>%s' % m for m in self.merges)
    return hashlib.sha256(s.encode('utf-8')).hexdigest()[16]
```

指紋涵蓋 **id 的順序** (`itos` 是有序的)，所以順序一變就會被抓到。

存檔時一起寫進去，載入時比對：

```
model.save('out/model.pt', tokenizer_fingerprint=tok.fingerprint())
model.load('out/model.pt', tokenizer_fingerprint=tok.fingerprint())
```

拿錯就直接擋下來：

```
ValueError: tokenizer 不符！
權重存檔時用的 : dcb6ef062b94a20e
現在載入的      : deadbeefdeadbeef
詞表大小可能一樣，但 id 對應不同——模型會照跑，輸出卻是垃圾。
要強制載入請傳 strict_tokenizer=False。
```

這是 20 行程式碼就能省下好幾天除錯時間的那種投資。

如果真的需要改 tokenizer

可以：擴充 (append)

保留原有的 id `0..V-1` 完全不動，只在後面接新的列：

```
p[:old_vocab].copy_(old_E)          # 原有 id 原封不動
p[old_vocab:] = old_E.mean(0)       # 新列用既有向量的平均值起步
```

實測 (詞表 6,400 → 6,450)：

```
同一句話的 loss = 3.6130    (原本 3.6129，差 0.0000)
```

幾乎沒有影響，因為原有的 id 對應沒被動到。這就是做語言擴充、加領域詞彙時的標準做法。

新列的初始化有幾種常見選擇：

做法	說明
既有向量的平均	最簡單，起點中性
小亂數	跟從頭訓練一致
子詞平均	新 token 是 機器學習，就用 機、器、學、習 四個舊向量的平均

第三種通常最好——新 token 一開始就落在語意上合理的位置。

不行：重建（rebuild）

用新語料重訓一個 tokenizer，即使詞表大小相同、甚至詞彙集合相同，只要 id 的分配順序不同，權重就報廢了。

BPE 的 id 順序取決於合併的順序，而合併順序取決於語料的統計。換語料、換種子、甚至換一個實作的 tie-breaking 規則，順序就會不一樣。

折衷：詞表移植（tokenizer transplant）

如果非換不可，可以做「字串比對搬家」：

對新詞表的每個 token：

如果舊詞表裡有同樣的字串 → 把舊向量搬過來

否則 → 用子詞平均初始化

能救回一部分，但一定會掉品質，需要再訓練一段時間補回來。業界做跨語言適配時常用這招，但那是不得已，不是首選。

一句話

權重跟 tokenizer 是一組的，發布時要一起發布，換模型時要一起換。

只能往後擴充，不能重建。

這也是為什麼 HuggingFace 上的模型 repo 一定會把 `tokenizer.json` 跟 `model.safetensors` 放在同一個目錄——它們不是兩個獨立的東西。

RMSNorm

對應程式碼：`scratch/rmsnorm.py`


每一層的入口都會先過它。整個模型裡它的參數量最少（每層只有 d 個），但影響最大——它決定了進入 Attention 和 FFN 的數值尺度。

前向

$$r = \sqrt{\frac{1}{n} \sum_{k=1}^n x_k^2 + \varepsilon}$$
$$\hat{x} = \frac{x}{r}$$
$$y = g \odot \hat{x}$$

三個步驟，三個角色：

符號	是什麼	可學嗎
r	這一系列數字的均方根（root-mean-square）	否，算出來的
$\hat{x}$	正規化後的向量，長度被拉到約 $\sqrt{n}$	否
g	每個維度一個的縮放係數	是，初始值全為 1
ε	防止除以零，預設 10^{-5}	否，固定常數



沿哪一維做正規化很重要：是沿最後一維（特徵維度），所以每個位置各自正規化，位置與位置之間互不影響。

跟 LayerNorm 的差別

LayerNorm: $y = g \odot \frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}} + b$

$$\text{RMSNorm: } y = g \odot \frac{x}{\sqrt{\text{mean}(x^2) + \epsilon}}$$

RMSNorm 少了兩樣東西：

1. 不減平均數 μ
2. 沒有偏置 b

少一次減法、少一組參數，實測效果幾乎一樣。所以現在的 LLM（LLaMA、Mistral、Qwen、minimind）幾乎都用 RMSNorm。

實際數值

從 `traces/sample/train_step_0001.txt` 抓的第一層 `norm1`：

	前 4 個維度
x（輸入）	+0.01647 -0.04764 +0.02504 +0.00472
r	0.019711
$\hat{x}$ （正規化後）	+0.83548 -2.41710 +1.27034 +0.23929
g（初始值）	+1.00000 +1.00000 +1.00000 +1.00000
y（輸出）	+0.83548 -2.41710 +1.27034 +0.23929

驗算第一個維度：

$$\hat{x}_1 = \frac{0.01647}{0.019711} = 0.83557 \approx 0.83548$$

（差在四捨五入。）

注意這個放大倍率：

$$\frac{1}{r} = \frac{1}{0.019711} = 50.7$$

embedding 出來的向量很小（每個元素約 0.02），RMSNorm 把它們放大了 50 倍。這不是 bug，正是它的用途——把不同來源、不同尺度的向量統一到同一個工作區間。

反向（逐步推導）

設 n 是維度數， $a_i = \partial L / \partial y_i g_i$ 。

第一步：r 對 x 的偏導

$$r = \left(\frac{1}{n} \sum_k x_k^2 + \varepsilon \right)^{1/2}$$

用連鎖律：

$$\frac{\partial r}{\partial x_j} = \frac{1}{2} \left(\frac{1}{n} \sum_k x_k^2 + \varepsilon \right)^{-1/2} \cdot \frac{2x_j}{n} = \frac{x_j}{n r}$$

第二步：y 對 x 的偏導

這裡是關鍵—— y_i 透過**兩條路**依賴 x_j ：

1. 分子裡的 x_i 本身（只有 $i=j$ 時）
2. 分母 r 裡面也含有 x_j （每個 j 都有）

$$y_i = g_i \frac{x_i}{r}$$

用商法則：

$$\frac{\partial y_i}{\partial x_j} = g_i \left[\frac{\delta_{ij}}{r} - \frac{x_i}{r^2} \cdot \frac{\partial r}{\partial x_j} \right] = g_i \left[\frac{\delta_{ij}}{r} - \frac{x_i x_j}{n r^3} \right]$$

其中 δ_{ij} 是 Kronecker delta（ $i=j$ 時為 1，否則為 0）。

第三步：連鎖律加總

$$\frac{\partial L}{\partial x_j} = \sum_i \frac{\partial L}{\partial y_i} \cdot \frac{\partial y_i}{\partial x_j} = \frac{a_j}{r} - \frac{x_j}{n r^3} \sum_i a_i x_i$$

第四步：化簡

把 $x = \hat{x}r$ 代入第二項：

$$\frac{x_j}{n r^3} \sum_i a_i x_i = \frac{\hat{x}_j r}{n r^3} \cdot r \sum_i a_i \hat{x}_i = \frac{\hat{x}_j}{r} \cdot \frac{1}{n} \sum_i a_i \hat{x}_i$$

得到最後要寫進程式的形式：

$$\boxed{\frac{\partial L}{\partial x} = \frac{1}{r} \left(a - \hat{x} \cdot \text{mean}(a \odot \hat{x}) \right), \quad a = \frac{\partial L}{\partial y} \odot g}$$

對 g 的梯度

單純得多，因為 $y = g \odot \hat{x}$ 裡 g 只出現一次：

$$\frac{\partial L}{\partial g} = \sum_{\text{所有位置}} \frac{\partial L}{\partial y} \odot \hat{x}$$


第二項在做什麼

$$-\hat{x} \cdot \text{mean}(a \odot \hat{x})$$

它的作用是把梯度中沿著 $\hat{x}$ 方向的分量扣掉。

理由： $\hat{x}$ 的長度已經被 r 固定住了（ $\|\hat{x}\| = \sqrt{n}$ ）。沿著它自己的方向推，只會改變長度——而長度馬上又會被正規化消掉，所以那個方向的梯度是無效的，扣掉才正確。

幾何上，這是把梯度投影到與 $\hat{x}$ 垂直的超平面上。



一個實測現象：梯度會被放大

前向除以 $r = 0.0197$ ，反向經過同一個除法時，梯度也會被放大差不多的倍數。

這就是為什麼梯度從第 1 層傳到 embedding 時會突然大一個數量級。

實測倍率會比 $1/r = 50.7$ 略小，因為第二項扣掉了一部分。

驗證

`tests/test_layers.py` 用有限差分驗證這一層：

$$\frac{\partial L}{\partial w} \approx \frac{L(w + \varepsilon) - L(w - \varepsilon)}{2\varepsilon}$$

結果：最大相對誤差 2.13×10^{-7} ，**PASS**。


（這一層的誤差比 Linear 的 10^{-12} 大，是因為它含有開根號和除法，浮點運算的累積誤差比較多。 10^{-7} 對 `float64` 來說仍在合理範圍。）


Attention 的結構

對應程式碼：[scratch/attention.py](#)

整個模型裡**唯一讓不同位置互相看得到的地方**。FFN 是每個位置各做各的，只有 Attention 會橫向交換資訊。

全貌





注意 **V 不做 RoPE**——位置資訊只需要影響「誰該注意誰」（分數），不需要影響「注意到之後拿到什麼內容」。

一、三條投影

$$Q = xW_Q^\top, \quad K = xW_K^\top, \quad V = xW_V^\top$$

同一個 x 走了三條獨立的線性層，產生三個角色：


	名稱	直覺
Q	Query，查詢	「我在找什麼」
K	Key，鍵	「我是什麼」
V	Value，值	「我能提供什麼內容」

因為 x 分岔成三路，**反向時三份梯度要相加**：

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial x}\bigg|_Q + \frac{\partial L}{\partial x}\bigg|_K + \frac{\partial L}{\partial x}\bigg|_V$$

二、拆成多個 head

$$(B, T, d) \longrightarrow (B, h, T, d_{\text{head}}), \quad d_{\text{head}} = \frac{d}{h}$$



不是複製四份，是把 256 維切成四段，每段獨立算注意力。這樣參數量完全沒增加，但模型可以同時關注不同類型的關係（例如一個 head 管語法、一個管指代）。

三、注意力分數

$$S = \frac{QK^{\top}}{\sqrt{d_{\text{head}}}}$$

S_{ij} 的意思是「位置 i 對位置 j 的關注程度」，本質是兩個向量的點積。

為什麼要除以 $\sqrt{d_{\text{head}}}$

假設 Q 、 K 各維度獨立、變異數約為 1，那麼點積

$$S_{ij} = \sum_{k=1}^{d_{\text{head}}} q_{ik} k_{jk}$$

是 d_{head} 個獨立項的和，變異數變成 d_{head} ，標準差 $\sqrt{d_{\text{head}}}$ 。

$d_{\text{head}} = 64$ 時，分數會散到 ± 8 以上。softmax 吃到這種輸入會變得**極度尖銳**（幾乎變成 one-hot），而 softmax 在飽和區的梯度趨近於零——**梯度就消失了**。

除以 $\sqrt{d_{\text{head}}}$ 把變異數拉回 1，softmax 才處在有梯度的區間。

實測本專案的設定： $d_{\text{head}} = 64$ ， $\text{scale} = 1/\sqrt{64} = 0.125$ 。

四、因果遮罩

語言模型只能用「已經看過的字」預測下一個字。所以位置 i 只能注意 $j \leq i$ ：

$$S_{ij} \leftarrow -\infty \quad \text{if } j > i$$

$\exp(-\infty) = 0$ ，所以那些位置的注意力權重變成 0，等於不存在。

遮罩矩陣長這樣（✓ 可以看，空白被擋住）：

	j=0	j=1	j=2	j=3	j=4
i=0	✓				
i=1	✓	✓			
i=2	✓	✓	✓		
i=3	✓	✓	✓	✓	
i=4	✓	✓	✓	✓	✓

下三角。這也是為什麼一次前向就能同時訓練 T 個位置的預測——每個位置看到的都是「只到自己為止」的資訊，互不干擾。

五、softmax

$$A = \text{softmax}(S), \quad A_{ij} = \frac{\exp(S_{ij})}{\sum_k \exp(S_{ik})}$$

沿**最後一維**做，所以每一列加起來等於 1：

$$\sum_j A_{ij} = 1 \quad \text{對每個 } i$$

實際跑出來的注意力矩陣（[traces/sample/train_step_0001.txt](#)，第 0 個 head，訓練第 1 步）：

	j=0	j=1	j=2	j=3	j=4	列和
i=0	1.00000					1.0
i=1	0.43477	0.56523				1.0
i=2	0.35364	0.28259	0.36377			1.0
i=3	0.21434	0.32812	0.22678	0.23077		1.0
i=4	0.23005	0.15862	0.16002	0.20928	0.24203	1.0

三件事一眼可見：

1. 上三角全是空的——因果遮罩生效了
 2. 每列和都是 1.0——softmax 正確
 3. 權重相當平均（i=4 那列都在 0.16 ~ 0.24 之間）——因為這是訓練第 1 步，權重還是亂數，模型還不知道該注意誰。訓練久了會出現明顯的尖峰。
-

六、加權求和與合併


$$O = AV, \quad O_i = \sum_j A_{ij} V_j$$

每個位置的輸出，是所有它看得到的位置的 V 的加權平均，權重就是注意力。

$$(B, h, T, d_{\text{head}}) \longrightarrow (B, T, d) \xrightarrow{W_O} y$$

`o_proj` 的作用是把各個 head 的結果混合起來——沒有它，各 head 算完就直接拼接，彼此之間永遠不會互動。

反向



對 A 與 V

$O = AV$ 是矩陣乘法，套用標準結果：

$$\frac{\partial L}{\partial A} = \frac{\partial L}{\partial O} V^\top, \quad \frac{\partial L}{\partial V} = A^\top \frac{\partial L}{\partial O}$$

(又是「點積對一邊微分得到另一邊」。)

softmax 的完整反向

這裡**沒有** cross-entropy 接在後面，所以不能用 $p - y$ 那個簡化，必須用完整形式。對每一列 i 獨立：

$$\frac{\partial A_{ij}}{\partial S_{ik}} = A_{ij} (\delta_{jk} - A_{ik})$$

$$\boxed{\frac{\partial L}{\partial S_{ij}} = A_{ij} \left(\frac{\partial L}{\partial A_{ij}} - \sum_k \frac{\partial L}{\partial A_{ik}} A_{ik} \right)}$$

括號裡那個 $\sum$ 是**這一系列的加權平均**，每列算一次就好，不需要真的建出 $T \times T$ 的 Jacobian。

遮罩不用特別處理：被遮住的位置 $A_{ij} = 0$ ，公式最前面的 A_{ij} 自動讓那些梯度也是 0。

對 Q 與 K

$$\frac{\partial L}{\partial Q} = \frac{1}{\sqrt{d_{\text{head}}}} \frac{\partial L}{\partial S} K, \quad \frac{\partial L}{\partial K} = \frac{1}{\sqrt{d_{\text{head}}}} \left(\frac{\partial L}{\partial S} \right)^\top Q$$

記憶體：為什麼 Attention 是 $O(T^2)$

分數矩陣的形狀是

$$S \in \mathbb{R}^{B \times h \times T \times T}$$

以 $B=64$ 、 $h=4$ 、 $T=128$ 為例：

$$64 \times 4 \times 128 \times 128 = 4.19 \times 10^6$$

序列長度加倍，這個張量會變成**四倍**。而且訓練時 A 要存下來給反向用。

這就是長 context 昂貴的根本原因，也是 FlashAttention 這類技術要解決的問題（它的作法是分塊計算、不把完整的 S 物化出來）。

驗證

`tests/test_layers.py` 對這一層的有限差分驗證：最大相對誤差 3.32×10^{-7} ，**PASS**。

含 softmax Jacobian、因果遮罩、RoPE 反向、三路梯度相加，全部推對。


FFN 的結構 (SwiGLU)

對應程式碼：[scratch/swiglu.py](#)

Attention 負責**橫向**（位置之間交換資訊），FFN 負責**縱向**（每個位置各自加工）。FFN 對第 7 個位置做的事，跟它對第 13 個位置做的事完全獨立。

而且它是每一層裡**參數量最大**的部分——通常佔三分之二以上。

全貌



$$g = xW_{\text{gate}}^{\top}, \quad u = xW_{\text{up}}^{\top}, \quad s = \text{SiLU}(g), \quad m = s \odot u, \quad y = mW_{\text{down}}^{\top}$$

寫成一行：

$$y = \left(\text{SiLU}(xW_{\text{gate}}^{\top}) \odot xW_{\text{up}}^{\top} \right) W_{\text{down}}^{\top}$$

跟原始 Transformer 的 FFN 比較

原始 (2017) : $y = \text{ReLU}(xW_1 + b_1)W_2 + b_2$


SwiGLU: $y = (\text{SiLU}(xW_{\text{gate}}) \odot xW_{\text{up}})W_{\text{down}}$

	原始	SwiGLU
矩陣數	2	3
非線性	ReLU	SiLU (平滑, 處處可微)
閘門機制	無	有 (多出來的 up 那一路)
bias	有	無

多出來的那一路 u 的作用是**開關**：s 決定 u 的每個維度要放行多少。

因為多了一個矩陣，為了維持總參數量相當，d_ff 通常取 8/3d 而不是傳統的 4d。

為什麼要先升維再降回來



在高維空間裡，資料更容易被非線性「切開」。先升維、加工、再壓回來——這是 FFN 的標準套路。

參數量因此很可觀：

$$|\theta_{\text{FFN}}| = 3 \times d \times d_{\text{ff}} = 3 \times 256 \times 672 = 516,096$$

$$|\theta_{\text{Attention}}| = 4 \times d^2 = 4 \times 256^2 = 262,144$$

FFN 大約是 Attention 的兩倍。一層裡三分之二的參數都在 FFN。

SiLU 這個非線性

$$\text{SiLU}(z) = z \sigma(z) = \frac{z}{1 + e^{-z}}$$

(也叫 Swish。)

z	$\sigma(z)$	$\text{SiLU}(z)$
-3	0.047	-0.142
-1	0.269	-0.269
0	0.500	0.000
1	0.731	0.731
3	0.953	2.858

跟 ReLU 比：

- **負數區不是直接砍成 0**，而是留下一點負值（最小值約 -0.278）。ReLU 的「死神經元」問題（一旦進入負區梯度永遠是 0）在這裡不存在。
- **處處可微**，沒有 ReLU 在 $z=0$ 的折點。

導數（用 $\sigma' = \sigma(1-\sigma)$ 推）：

$$\text{SiLU}'(z) = \sigma(z) + z \sigma(z)(1 - \sigma(z)) = \sigma(z) \left(1 + z(1 - \sigma(z)) \right)$$

閘門在做什麼（用真實數值看）

從 `traces/sample/train_step_0001.txt` 抓的第一層 FFN，前 4 個維度：

維度	g (gate)	$s = \text{SiLU}(g)$	u (up)	$m = s \odot u$
1	-1.00882	-0.26957	-0.59599	+0.16066
2	-0.32442	-0.13613	+0.28378	-0.03863
3	+0.33926	+0.19813	-0.03482	-0.00690
4	-1.21415	-0.27800	-0.69361	+0.19282


驗算第 1 個維度：

$$\text{SiLU}(-1.00882) = -1.00882 \times \sigma(-1.00882) = -1.00882 \times 0.2672 = -0.2696 \checkmark$$

$$m_1 = s_1 \times u_1 = (-0.26957) \times (-0.59599) = +0.16066 \checkmark$$

看第 3 個維度： $u_3 = -0.03482$ 本身就很小，乘上 $s_3 = 0.198$ 之後變成 -0.0069——**幾乎被關掉了**。這就是 gating：即使 u 那一路算出了東西， s 可以決定讓它過多少。

反向



逐條寫出來：

$$\frac{\partial L}{\partial m} = \text{down_proj.backward}\left(\frac{\partial L}{\partial y}\right)$$

$m = s \odot u$ 是逐元素相乘，對一邊微分得到另一邊：

$$\frac{\partial L}{\partial s} = \frac{\partial L}{\partial m} \odot u, \quad \frac{\partial L}{\partial u} = \frac{\partial L}{\partial m} \odot s$$

再過 SiLU 的導數：

$$\frac{\partial L}{\partial g} = \frac{\partial L}{\partial s} \odot \text{SiLU}'(g)$$

最後兩路回到 x ，**梯度相加**：

$$\frac{\partial L}{\partial x} = \text{gate_proj.backward}\left(\frac{\partial L}{\partial g}\right) + \text{up_proj.backward}\left(\frac{\partial L}{\partial u}\right)$$

x 同時餵給 gate 和 up 兩條路，所以反向要把兩份加起來——**前向分岔，反向相加**，這條通則在整份程式碼裡反覆出現。

記憶體：FFN 是訓練時的活化值大戶

反向需要用到 g、s、u，所以前向時全都要存下來。每一個的形狀都是 (B,T,d_ff)。

以 B=64、T=128、d_ff=672、bf16 為例，單一個張量：

$$64 \times 128 \times 672 \times 2 \text{ bytes} = 11 \text{ MB}$$

一層要存三個 (g、s、u) 約 33 MB，四層就是 132 MB。

這就是「訓練比推論吃記憶體」的主因之一——**推論不用存這些，算完就丟**。

驗證

`tests/test_layers.py` 對這一層的有限差分驗證：最大相對誤差 1.69×10^{-6} ，**PASS**。

(這是九層裡誤差最大的一個，因為 SiLU 的導數含有 $\sigma(1-\sigma)$ ，連續兩次浮點運算的誤差會累積。 10^{-6} 仍在合理範圍。)

完整執行紀錄

從乾淨狀態跑完整條流程，每個階段都是「指令 → 程式碼在做什麼 → 實際輸出」三段式。

這份文件怎麼讀

追蹤檔的資料量很大——單一個 `train_step_0001.txt` 就有 **926 行 / 59 KB**。全部貼出來沒有意義，所以這裡採三層呈現：

層	做什麼	在哪
摘要	一張表說明產出了什麼檔案、多大、要看什麼	產出的檔案
骨架	長檔案的章節目錄與行號，知道去哪裡找	怎麼讀 926 行的追蹤檔
精選	5 個關鍵片段，配上對應的程式碼	下面每個階段

原則：這份文件負責告訴你「該看哪幾行」，不負責取代那些檔案。

環境

GPU	NVIDIA RTX PRO 6000 Blackwell (96 GB)
Python	3.12, torch 2.9.1+cu130
語料	<code>data/corpus_zhtw.jsonl</code> 前 20,000 行
總耗時	梯度驗證 3 秒 + BPE 訓練 12 秒 + 模型訓練 79 秒

```
rm -rf out traces          # 從乾淨狀態開始
```

階段 1：驗證所有手推的公式

```
python tests/test_layers.py
```

程式碼在做什麼

不用 PyTorch 的 autograd 對答案，而是回到梯度的**定義**直接量：

$$\frac{\partial L}{\partial w} \approx \frac{L(w + \varepsilon) - L(w - \varepsilon)}{2\varepsilon}$$

```
# scratch/gradcheck.py (節錄)
y0 = layer.forward(x)
dy = torch.randn(y0.shape)          # 隨機的上游梯度
dx = layer.backward(dy)              # 手推公式算出來的

flat[i] = orig + eps; lp = float((layer.forward(x) * dy).sum())
flat[i] = orig - eps; lm = float((layer.forward(x) * dy).sum())
num = (lp - lm) / (2 * eps)          # 有限差分算出來的
rel = abs(num - float(dx.reshape(-1)[i])) / ...
```

人工造一個純量 loss $L = \sum(y \odot dy)$ ，這樣 $\partial L / \partial y$ 剛好等於 dy ，就能用任意的 dy 去測 backward 對不對。

用**中央差分**而不是單邊，因為誤差是 $O(\epsilon^2)$ 而不是 $O(\epsilon)$ 。整個檢查跑在 `float64` 上，避免 `float32` 的捨入誤差蓋過訊號。

實際輸出

梯度檢查 (有限差分 vs 手推公式)

```
=====
Linear 無bias          最大相對誤差 2.29e-12  PASS
Linear 有bias          最大相對誤差 2.03e-12  PASS
RMSNorm                最大相對誤差 2.13e-07  PASS
Embedding (scatter-add) 最大相對誤差 6.80e-14  PASS
TiedOutputHead         最大相對誤差 5.61e-12  PASS
SwiGLU                 最大相對誤差 1.69e-06  PASS
rope                   最大相對誤差 2.19e-12  PASS
Attention               最大相對誤差 3.32e-07  PASS
Softmax+CrossEntropy   最大相對誤差 7.50e-08  PASS
=====
最差相對誤差 1.69e-06  -> 全部通過
```

誤差大小的差異是有意義的：純矩陣運算的層（Linear、Embedding、RoPE）在 10^{-12} 等級，含開根號、除法、 $\sigma(1-\sigma)$ 的層（RMSNorm、SwiGLU）在 $10^{-6} \sim 10^{-7}$ ，因為浮點誤差會累積。

階段 2：訓練 BPE tokenizer

```
python train.py --tokenizer bpe --vocab 6400 ...
```


程式碼在做什麼

$$|\mathcal{V}| = |\mathcal{V}_0| + M$$

反覆合併最高頻的相鄰配對，每合併一次詞表 +1，到目標大小就停。

```
# tokenizer/bpe.py (節錄)
for step in range(n_merges):
    pair, cnt = max(pair_cnt.items(), key=lambda kv: kv[1]) # 最高頻的配對
    new_sym = pair[0] + pair[1]
    for i in pair_where[pair]: # 只更新受影響的詞塊
        deindex_word(i)
        ...把 pair 換成 new_sym...
        index_word(i)
    tk.merges.append(pair)
    tk.itos.append(new_sym) # 詞表 +1
```

`pair_where` 記錄「哪些詞塊含有這個配對」，合併時只更新受影響的那些，不用每輪重掃整份語料——否則 1,173 次合併會跑很久。

實際輸出

```
詞塊 1,826,987 個（相異 599,629 個），字元 5,415,807 個
起始詞表 5,227（4 特殊 + 5,223 字元）
目標 6,400 → 需要合併 1,173 次

合併 #1      '可' + '以' -> '可以' （23,763 次） 詞表 5,228
合併 #1000   '生' + '產' -> '生產' （393 次）   詞表 6,227

完成，最終詞表 6,400
```

$5,227 + 1,173 = 6,400$ 。這就是「詞表 6400 哪來的」的答案。

注意合併次數一路遞減： $23,763 \rightarrow 393$ 。這給了一個實用判斷——如果最後幾次合併降到個位數，代表詞表開太大了。

完整的合併紀錄：`traces/bpe_training.txt`（54 行）

階段 3：訓練模型

模型規格

模型結構

=====	
embedding	1,638,400
block0	778,752
block1	778,752
block2	778,752
block3	778,752
final_norm	256
lm_head (與 embedding 共用)	0

總計	4,753,664
embedding 佔比	34.5%

optimizer 拿到 38 個參數張量

`lm_head` 是 0，因為它跟 embedding 共用同一個張量（weight tying）。`optimizer` 拿到 38 個張量——**embedding 就在這 38 個裡面**，跟 `q_proj` 平起平坐。

訓練迴圈

```
# train.py (節錄)
model.zero_grad()
logits = model.forward(x, tr)      # 前向
loss   = ce.forward(logits, y, tr) # 算 loss
dlogits = ce.backward(tr)          # dz = (p - y) / N
model.backward(dlogits, tr)         # 反向，逐層往下

gnorm = opt.clip_grad_norm(args.clip) # 全域梯度裁剪
opt.step(tr, watch='embed.E')         # 這一行才真的改動權重
```

注意 `model.backward()` 和 `opt.step()` 是兩件事。前者只算出「該往哪修」存進梯度表，後者才動權重。

loss 曲線

step	loss	lr	梯度範數	秒
1	8.8149	3.000e-05	0.8127	0.4
200	5.3237	2.992e-03	0.3945	5.7
500	4.2052	2.875e-03	0.3919	13.6
1000	3.6166	2.408e-03	0.3512	26.8
1500	3.1605	1.723e-03	0.3512	40.0
2000	3.0630	1.018e-03	0.3594	53.1
2500	2.9718	4.932e-04	0.3764	66.2
3000	2.7806	3.000e-04	0.3886	79.4

8.81 → 2.78，79 秒。lr 的形狀是 warmup（前 100 步爬升）接 cosine 衰減。

完整曲線每 20 步一筆：`traces/train_log.txt`（152 行）

階段 4：生成

```
python generate.py --prompt "機器學習是"
```

實際輸出

機器學習是一項重要的領域，即將資料能夠從大量資料中學習和推理。
機器學習可以用於學習、自然語言處理和自然語言生成等各種任務。

台灣的天氣如今，在這裡有著令人無法抗衰老的環境和繁華性災難。
這些災難事件可以用於對當地居民群落和探討。

貓是一種常見的寵物，並且常常會受到許多人關注和感悟。
狗通常很快地奔跑、游泳、跳傘……

第一段語意通順、術語正確。後兩段語法沒問題但語意會飄——這就是 475 萬參數、吃 424 萬 token 該有的水準。

（機器學習 被 BPE 合併成單一 token，所以模型對它的處理特別穩。）

階段 5：權重與 tokenizer 綁定

```
python tests/test_tokenizer_binding.py
```

實際輸出

① 正確的 tokenizer loss = 3.5754
② id 對應被打亂 loss = 12.0569

換算成 perplexity（等效於在幾個選項中亂猜）：

正確 tokenizer 35.7

打亂之後 : 172287.4

完全隨機的模型 6400.0

③ 詞表大小不同 -> RuntimeError: size mismatch（安全，馬上知道出事）

④ 擴充 6400 -> 6450，同一句話 loss 幾乎不變

用錯 tokenizer 比完全沒訓練過的模型還糟 27 倍，而且不會報錯。所以 `model.save()` 會把 tokenizer 的指紋一起存進去，載入時比對。

產出的檔案

檔案	行數	大小	看什麼
<code>gradcheck.txt</code>	18	0.9 KB	九層的驗證總表，可直接貼進簡報
<code>model_summary.txt</code>	32	1.1 KB	參數量分佈與所有超參數
<code>bpe_training.txt</code>	54	4.0 KB	詞表怎麼從 5,227 長到 6,400
<code>train_log.txt</code>	152	8.6 KB	每 20 步的 loss / lr / 梯度範數
<code>inference.txt</code>	456	28.6 KB	一次推論的完整前向（沒有反向）
<code>train_step_0001.txt</code>	926	58.8 KB	第 1 步的完整前向 + 反向 + 更新
<code>train_step_3000.txt</code>	925	58.8 KB	最後一步，可跟第 1 步對照
<code>out/model.pt</code>	—	18.6 MB	訓練好的權重
<code>out/tokenizer_bpe.json</code>	—	65 KB	詞表與合併規則

怎麼讀 926 行的追蹤檔

不要從頭讀。先看骨架，再跳到想看的地方。

骨架（行號可直接跳）

```
8  這一批的資料          ← 這批文字長什麼樣
19 前向傳播
25  embed · forward (查表)
45  ===== block0 ===== ← 每個 block 約 100 行
474 softmax + cross-entropy · forward
493 softmax + cross-entropy · backward ← p - y 在這裡
510 反向傳播
776  ===== block0 · backward =====
851  embed · backward (scatter-add) ← 兩條梯度路徑的拆解
889 AdamW 更新（第 1 步）      ← 權重真正被改的地方
917 這一步結束
```

`block1` / `block2` / `block3` 的結構跟 `block0` 一模一樣，看一個就夠。

導覽：五個最值得看的片段

① 第 25 行 — 查表就是查表

公式： $x = E[\text{ids}]$

等價於 $x = \text{one_hot}(\text{ids}) @ E$ ，只是跳過了乘以 0 的部分

`ids` `shape (64, 128)`

`x` `shape (64, 128, 256)`

位置	查哪一列	E[id] 的前 4 維			
t=0	id=4	+0.01647	-0.04764	+0.02504	+0.00472
t=1	id=5868	-0.00623	+0.02665	-0.00391	-0.01012

>> 這一批用到 2036 個不同的 token，詞表共 6400 個。

>> 剩下 4364 列這一步完全沒被碰到——反向時它們的梯度會是 0。

前向沒有任何乘法，就是索引。記住 2036 / 6400 這個數字，第 ④ 點會用到。

② 第 493 行 — 整條鏈唯一知道答案的地方

公式: $dz = (p - y) / N$

token id	p	y	$dz = (p-y)/N$	作用
4656	+0.00048	+0.00000	+5.920e-08	壓下去
220	+0.00046	+0.00000	+5.575e-08	壓下去
5868	+0.00026	+1.00000	-0.00012	拉上來（正解）

正解那一格 $y = 1$ ，所以 dz 是**負的**。更新時 $E \leftarrow E - \eta dz$ ，負負得正，分數被推高。其他格全是正的，分數被壓低。

這一行就是整個訓練的全部監督訊號。往下每一層都只是機械式的微分。

③ 第 851 行 — scatter-add，以及它不是唯一的來源

公式: $dE[v] += \sum_{\{t : id_t = v\}} dx[t]$

這一系列的梯度其實是兩條路加起來的：

	來源	$dE[5][0]$	有幾列非零
輸入側（本步 scatter-add）		+0.00125	2036 / 6400 ← 稀疏
輸出側（weight tying）		-0.00420	6400 / 6400 ← 稠密
合計 $dE[5][0]$		-0.00295	6400 / 6400

2036 / 6400 正是第 ① 點那個數字——輸入側只碰得到出現過的 token。但因為 E 同時是分類器權重，softmax 會碰到**每一列**，所以總梯度是稠密的。

注意兩條路的符號還相反（+0.00125 vs -0.00420），合計後變號。

④ 第 889 行 — 位移恰好等於 lr

更新前 p	+0.00388	+0.04323	-0.00344	+0.01698
梯度 g	-1.290e-06	+8.668e-05	-5.620e-05	-6.518e-06
$\hat{m}$	-1.290e-06	+8.668e-05	-5.620e-05	-6.518e-06
$\sqrt{\hat{v}}$	+1.290e-06	+8.668e-05	+5.620e-05	+6.518e-06
$\hat{m}/(\sqrt{\hat{v}}+\epsilon)$	-0.99231	+0.99988	-0.99982	-0.99847
位移 Δ	+2.977e-05	-3.000e-05	+2.999e-05	+2.995e-05
lr				3.000e-05

看第 2 行和第 4 行：梯度從 1.29×10^{-6} 到 8.67×10^{-5} ，**差了 67 倍**。但位移全都是 $\pm 3 \times 10^{-5}$ ，**一模一樣**。

因為第一步時 $\hat{m} = g$ 、 $\sqrt{\hat{v}} = |g|$ ，相除必定是 ± 1 ：

$$\frac{\hat{m}_1}{\sqrt{\hat{v}_1}} = \frac{g}{|g|} = \text{sign}(g)$$

Adam 讓所有參數走一樣遠，差別只在方向。

⑤ 對照 train_step_3000.txt

同一個位置的數字，訓練 3000 步之後：

```
diff <(sed -n '493,500p' traces/train_step_0001.txt) \  
    <(sed -n '493,500p' traces/train_step_3000.txt)
```

第 1 步時正解的機率是 0.00026（幾乎是 1/6400 的隨機猜測），第 3000 步會明顯高出來。這是最直接的「模型學到東西了」的證據。

重跑

```
rm -rf out traces  
python tests/test_layers.py  
python train.py --tokenizer bpe --vocab 6400 --steps 3000 \  
    --dim 256 --layers 4 --heads 4 --seq 128 --batch 64 \  
    --trace-steps 1,3000  
python generate.py --prompt "機器學習是"  
python tests/test_tokenizer_binding.py
```

固定 seed（預設 42），所以數字可以完全重現。

教學文件

程式碼註解裡有完整的公式推導，這裡放的是**程式碼講不了的東西**：流程圖、全景視角、以及做簡報時的敘事順序。

建議順序

	文件	對應程式碼	一句話
0	符號說明	<code>tools/demo_operators.py</code>	先看這份 。⊙ 和 @ 都叫「乘」，但完全是兩回事
1	全景圖	—	一句話進去，到權重被改動，中間發生了什麼
2	詞表大小是怎麼決定的	<code>tokenizer/bpe.py</code>	「6400 個詞哪來的」
3	Embedding 與 scatter-add	<code>scratch/embedding.py</code>	查表為什麼是矩陣乘法，反向為什麼是相加
4	反向傳播全鏈	全部	從 <code>p - y</code> 一路走回 <code>E</code>
5	權重是怎麼被改的	<code>scratch/adamw.py</code>	反向算完之後才輪到 optimizer
6	三個最常見的誤解	—	做簡報時最值得講的三件事
7	權重與 tokenizer 綁定	<code>tests/test_tokenizer_binding.py</code>	為什麼 continual pre-training 必須用同一份詞表

單層深入

01-07 是主線敘事。下面三份把單一層拆開講到底：完整的公式推導、結構圖、以及從追蹤檔抓出來的真實數值。做簡報時每一份都可以獨立成一個段落。

	文件	對應程式碼	重點
8	RMSNorm	<code>scratch/rmsnorm.py</code>	完整前向與反向推導（含商法則），以及它為什麼會放大梯度
9	Attention 的結構	<code>scratch/attention.py</code>	六個步驟逐一拆解，含因果遮罩與 softmax 完整 Jacobian
10	FFN 的結構（SwiGLU）	<code>scratch/swiglu.py</code>	閘門機制、為什麼升維再降維、參數量為何佔三分之二

實際跑一遍

	文件	重點
11	完整執行紀錄	從乾淨狀態跑完整條流程。每階段「指令 → 程式碼解說 → 實際輸出」，並附上讀 926 行追蹤檔的導覽

附：怎麼產生講解用的素材

```
# ○ 與 @ 的差別，用最小的矩陣算給你看
python tools/demo_operators.py

# 兩條反向傳播規則的逐元素推導（為什麼  $\partial L / \partial x$  裡出現  $W$ 、 $\partial L / \partial W$  要轉置）
python tools/demo_backward.py

# 逐層梯度驗證表（可直接貼進簡報）
python tests/test_layers.py          # -> traces/gradcheck.txt

# BPE 合併過程，看詞表怎麼從 3653 長到 6400
python tests/test_bpe.py             # -> traces/bpe_training.txt

# 第 1 步的完整數值軌跡（前向 + 反向 + AdamW 每個中間量）
python train.py --trace-steps 1      # -> traces/train_step_0001.txt

# 一次推論的完整前向
python generate.py --prompt "貓是一種" --trace # -> traces/inference.txt

# 證明權重與 tokenizer 綁死（用錯會比沒訓練還糟）
python tests/test_tokenizer_binding.py
```

`traces/sample/` 裡有一份預先跑好的，不用執行就能看。

轉成 PDF

```
python tools/build_pdf.py          # 合併成一份（含封面、目錄）
python tools/build_pdf.py --split  # 每份文件各一個
```

PDF 就輸出在這個目錄，跟 markdown 放在一起。

流程是 markdown → HTML (KaTeX + Mermaid) → headless Chrome 列印。公式用 KaTeX 渲染、流程圖用 Mermaid 畫，兩者在 PDF 裡都是向量，放大不會糊。

改完文件記得跑 `python tools/check_latex.py` 驗證公式沒被工具鏈破壞。