



Attention 的結構

對應程式碼：[scratch/attention.py](#)

整個模型裡**唯一讓不同位置互相看得到的地方**。FFN 是每個位置各做各的，只有 Attention 會橫向交換資訊。

全貌





注意 **V 不做 RoPE**——位置資訊只需要影響「誰該注意誰」（分數），不需要影響「注意到之後拿到什麼內容」。

一、三條投影

$$Q = xW_Q^\top, \quad K = xW_K^\top, \quad V = xW_V^\top$$

同一個 x 走了三條獨立的線性層，產生三個角色：


	名稱	直覺
Q	Query，查詢	「我在找什麼」
K	Key，鍵	「我是什麼」
V	Value，值	「我能提供什麼內容」

因為 x 分岔成三路，**反向時三份梯度要相加**：

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial x}\Big|_Q + \frac{\partial L}{\partial x}\Big|_K + \frac{\partial L}{\partial x}\Big|_V$$

二、拆成多個 head

$$(B, T, d) \longrightarrow (B, h, T, d_{\text{head}}), \quad d_{\text{head}} = \frac{d}{h}$$



不是複製四份，是把 256 維切成四段，每段獨立算注意力。這樣參數量完全沒增加，但模型可以同時關注不同類型的關係（例如一個 head 管語法、一個管指代）。

三、注意力分數

$$S = \frac{QK^{\top}}{\sqrt{d_{\text{head}}}}$$

S_{ij} 的意思是「位置 i 對位置 j 的關注程度」，本質是兩個向量的點積。

為什麼要除以 $\sqrt{d_{\text{head}}}$

假設 Q 、 K 各維度獨立、變異數約為 1，那麼點積

$$S_{ij} = \sum_{k=1}^{d_{\text{head}}} q_{ik} k_{jk}$$

是 d_{head} 個獨立項的和，變異數變成 d_{head} ，標準差 $\sqrt{d_{\text{head}}}$ 。

$d_{\text{head}} = 64$ 時，分數會散到 ± 8 以上。softmax 吃到這種輸入會變得**極度尖銳**（幾乎變成 one-hot），而 softmax 在飽和區的梯度趨近於零——**梯度就消失了**。

除以 $\sqrt{d_{\text{head}}}$ 把變異數拉回 1，softmax 才處在有梯度的區間。

實測本專案的設定： $d_{\text{head}} = 64$ ， $\text{scale} = 1/\sqrt{64} = 0.125$ 。

四、因果遮罩

語言模型只能用「已經看過的字」預測下一個字。所以位置 i 只能注意 $j \leq i$ ：

$$S_{ij} \leftarrow -\infty \quad \text{if } j > i$$

$\exp(-\infty) = 0$ ，所以那些位置的注意力權重變成 0，等於不存在。

遮罩矩陣長這樣（✓ 可以看，空白被擋住）：

	j=0	j=1	j=2	j=3	j=4
i=0	✓				
i=1	✓	✓			
i=2	✓	✓	✓		
i=3	✓	✓	✓	✓	
i=4	✓	✓	✓	✓	✓

下三角。這也是為什麼一次前向就能同時訓練 T 個位置的預測——每個位置看到的都是「只到自己為止」的資訊，互不干擾。

五、softmax

$$A = \text{softmax}(S), \quad A_{ij} = \frac{\exp(S_{ij})}{\sum_k \exp(S_{ik})}$$

沿**最後一維**做，所以每一列加起來等於 1：

$$\sum_j A_{ij} = 1 \quad \text{對每個 } i$$

實際跑出來的注意力矩陣（[traces/sample/train_step_0001.txt](#)，第 0 個 head，訓練第 1 步）：

	j=0	j=1	j=2	j=3	j=4	列和
i=0	1.00000					1.0
i=1	0.43477	0.56523				1.0
i=2	0.35364	0.28259	0.36377			1.0
i=3	0.21434	0.32812	0.22678	0.23077		1.0
i=4	0.23005	0.15862	0.16002	0.20928	0.24203	1.0

三件事一眼可見：

1. 上三角全是空的——因果遮罩生效了
 2. 每列和都是 1.0——softmax 正確
 3. 權重相當平均（ $i = 4$ 那列都在 $0.16 \sim 0.24$ 之間）——因為這是訓練第 1 步，權重還是亂數，模型還不知道該注意誰。訓練久了會出現明顯的尖峰。
-

六、加權求和與合併


$$O = AV, \quad O_i = \sum_j A_{ij} V_j$$

每個位置的輸出，是所有它看得到的位置的 V 的加權平均，權重就是注意力。

$$(B, h, T, d_{\text{head}}) \longrightarrow (B, T, d) \xrightarrow{W_O} y$$

`o_proj` 的作用是把各個 head 的結果混合起來——沒有它，各 head 算完就直接拼接，彼此之間永遠不會互動。

反向



對 A 與 V

$O = AV$ 是矩陣乘法，套用標準結果：

$$\frac{\partial L}{\partial A} = \frac{\partial L}{\partial O} V^{\top}, \quad \frac{\partial L}{\partial V} = A^{\top} \frac{\partial L}{\partial O}$$

（又是「點積對一邊微分得到另一邊」。）

softmax 的完整反向

這裡**沒有** cross-entropy 接在後面，所以不能用 $p - y$ 那個簡化，必須用完整形式。對每一列 i 獨立：

$$\frac{\partial A_{ij}}{\partial S_{ik}} = A_{ij} (\delta_{jk} - A_{ik})$$

$$\boxed{\frac{\partial L}{\partial S_{ij}} = A_{ij} \left(\frac{\partial L}{\partial A_{ij}} - \sum_k \frac{\partial L}{\partial A_{ik}} A_{ik} \right)}$$

括號裡那個 $\sum$ 是**這一系列的加權平均**，每列算一次就好，不需要真的建出 $T \times T$ 的 Jacobian。

遮罩不用特別處理：被遮住的位置 $A_{ij} = 0$ ，公式最前面的 A_{ij} 自動讓那些梯度也是 0。

對 Q 與 K

$$\frac{\partial L}{\partial Q} = \frac{1}{\sqrt{d_{\text{head}}}} \frac{\partial L}{\partial S} K, \quad \frac{\partial L}{\partial K} = \frac{1}{\sqrt{d_{\text{head}}}} \left(\frac{\partial L}{\partial S} \right)^\top Q$$

記憶體：為什麼 Attention 是 $O(T^2)$

分數矩陣的形狀是

$$S \in \mathbb{R}^{B \times h \times T \times T}$$

以 $B = 64$ 、 $h = 4$ 、 $T = 128$ 為例：

$$64 \times 4 \times 128 \times 128 = 4.19 \times 10^6$$

序列長度加倍，這個張量會變成**四倍**。而且訓練時 A 要存下來給反向用。

這就是長 context 昂貴的根本原因，也是 FlashAttention 這類技術要解決的問題（它的作法是分塊計算、不把完整的 S 物化出來）。

驗證

`tests/test_layers.py` 對這一層的有限差分驗證：最大相對誤差 3.32×10^{-7} ，**PASS**。

含 softmax Jacobian、因果遮罩、RoPE 反向、三路梯度相加，全部推對。